

MAE5763 - Modelos Lineares Generalizados - Resolução da Lista 2

Guilherme Marthe - 8661962

3/11/2020

1 Exercício 1

No enunciado é apresentado o seguinte modelo

$$y_i = \alpha + \beta x_i + \epsilon_i$$

Onde $\epsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$ e σ^2 é conhecido. É pedido mostrar as equivalências entre as estatísticas de Wald, Razão de verossimilhanças e Escore quando se testa $H_0 : \beta = 0$ contra $H_1 : \beta \neq 0$. Como sugerido, vamos deixar todas elas em função da estimativa $\hat{\beta}$.

1.1 Estatística de Wald

Quando a estatística de Wald testa somente um parâmetro, como é o nosso caso, ela tem a seguinte forma

$$\xi_W = \frac{(\hat{\beta} - \beta^0)^2}{\hat{\text{Var}}(\hat{\beta})}$$

Para a hipótese solicitada $\beta^0 = 0$. Abaixo calculamos a variância de $\hat{\beta}$ a partir da matriz modelo X . Seja $\theta = (\alpha, \beta)^T$ o vetor de parâmetros do modelo em questão. A matriz de variância e covariância de θ é calculada por:

$$\text{Var}(\hat{\theta}) = \sigma^2 (X^T X)^{-1}$$

Onde a matriz modelo X é

$$X = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

E

$$\begin{aligned} X^T X &= \begin{bmatrix} 1 & \dots & 1 \\ x_1 & \dots & x_n \end{bmatrix} \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} = \begin{bmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{bmatrix} \\ &= \begin{bmatrix} n & n\bar{x} \\ n\bar{x} & \sum_{i=1}^n x_i^2 \end{bmatrix} \end{aligned}$$

Uma vez que $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$. O inverso é de $X^T X$ é

$$(X^T X)^{-1} = \frac{1}{nS_{xx}} \begin{bmatrix} \sum_{i=1}^n x_i^2 & -n\bar{x} \\ -n\bar{x} & n \end{bmatrix}$$

Onde $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$ E $\text{Var}(\hat{\theta}) = \frac{\sigma^2}{nS_{xx}} \begin{bmatrix} \sum_{i=1}^n x_i^2 & -n\bar{x} \\ -n\bar{x} & n \end{bmatrix}$. Então, $\text{Var}(\hat{\beta}) = \frac{\sigma^2}{S_{xx}}$.

Concluimos então que a estatística de Wald é

$$\xi_W = \frac{(\hat{\beta})^2}{\hat{\text{Var}}(\hat{\beta})} = \frac{\beta^2 S_{xx}}{\sigma^2}$$

Onde $\text{Var}(\hat{\beta}) = \hat{\text{Var}}(\hat{\beta})$, uma vez que σ^2 é conhecido.

##Estatística de razão de verossimilhanças

A estatística de razão de verossimilhanças é calculada a partir do valor da função de verossimilhanças do modelo estimado sob H_1 e sob H_0 . A expressão dessa estatística é

$$\xi_{RV} = 2\{L(\hat{\theta}) - L(\theta^0)\}$$

Todavia, o modelo linear que estamos avaliando é um caso de um MLG, sendo a distribuição normal a distribuição pertencente à família exponencial de interesse e a ligação canônica que é a identidade. Assim a estatística do teste de razão de verossimilhanças pode ser escrita como uma diferença de desvios:

$$\xi_{RV} = \phi \left[D(y; \mu^0) - D(y; \hat{\mu}) \right]$$

Onde, em termos dos parâmetros do modelo proposto

$$\begin{aligned} \hat{\mu}_i &= \hat{\alpha} + \hat{\beta}x_i \\ &= \bar{y} - \hat{\beta}\bar{x} + \hat{\beta}x_i \\ &= \bar{y} + \hat{\beta}(x_i - \bar{x}) \end{aligned} \tag{1}$$

No caso normal, os desvios são:

$$\xi_{RV} = \frac{1}{\sigma^2} \left(\sum_{i=1}^n (y_i - \hat{\mu}_i^0)^2 - \sum_{i=1}^n (y_i - \hat{\mu}_i)^2 \right)$$

Vamos manipulá-lo para deixá-lo em função das estimativas de β :

$$\begin{aligned} \xi_{RV} &= \frac{1}{\sigma^2} \left(\sum_{i=1}^n (y_i - \hat{\mu}_i^0)^2 - \sum_{i=1}^n (y_i - \hat{\mu}_i)^2 \right) \\ &= \frac{1}{\sigma^2} \left(\sum_{i=1}^n y_i^2 - 2\hat{\mu}_i^0 y_i + (\mu_i^0)^2 - y_i^2 - \hat{\mu}_i^2 + 2\hat{\mu}_i y_i \right) \end{aligned}$$

$$\begin{aligned}
&= \frac{1}{\sigma^2} \left(\sum_{i=1}^n (\mu_i^0)^2 - \hat{\mu}_i^2 - 2y_i(\hat{\mu}_i^0 - \hat{\mu}_i) \right) \\
&= \frac{1}{\sigma^2} \left(\sum_{i=1}^n ((\hat{\mu}_i^0 + \hat{\mu}_i)(\hat{\mu}_i^0 - \hat{\mu}_i) - 2y_i(\hat{\mu}_i^0 - \hat{\mu}_i)) \right) \\
&= \frac{1}{\sigma^2} \left(\sum_{i=1}^n ((\hat{\mu}_i^0 + \hat{\mu}_i) - 2y_i)(\hat{\mu}_i^0 - \hat{\mu}_i) \right)
\end{aligned}$$

Agora vamos substituir os parâmetros da média usando (1) e o fato de que $\hat{\mu}_i^0 \stackrel{H_0}{=} \hat{\alpha}^0 \stackrel{H_0}{=} \bar{y}$:

$$\begin{aligned}
\xi_{RV} &= \frac{1}{\sigma^2} \left(\sum_{i=1}^n ((\hat{\mu}_i^0 + \hat{\mu}_i) - 2y_i)(\hat{\mu}_i^0 - \hat{\mu}_i) \right) \\
&= \frac{1}{\sigma^2} \left(\sum_{i=1}^n (2\bar{y} + \hat{\beta}(x_i - \bar{x}) - 2y_i)(-\hat{\beta}(x_i - \bar{x})) \right) \\
&= \frac{1}{\sigma^2} \left(\sum_{i=1}^n (\hat{\beta}(x_i - \bar{x}) - 2(y_i - \bar{y}))(-\hat{\beta}(x_i - \bar{x})) \right) \\
&= \frac{1}{\sigma^2} \left(\sum_{i=1}^n 2\hat{\beta}(x_i - \bar{x})(y_i - \bar{y}) - \hat{\beta}^2(x_i - \bar{x})^2 \right) \\
&= \frac{1}{\sigma^2} 2\hat{\beta} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) - \hat{\beta}^2 \sum_{i=1}^n (x_i - \bar{x})^2 \\
&= \frac{1}{\sigma^2} \left[2\hat{\beta} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) - \hat{\beta}^2 \sum_{i=1}^n (x_i - \bar{x})^2 \right] \\
&= \frac{1}{\sigma^2} [2\hat{\beta}S_{xy} - \hat{\beta}^2S_{xx}] \\
&= \frac{1}{\sigma^2} \left[2\hat{\beta}S_{xy} \frac{S_{xx}}{S_{xx}} - \hat{\beta}^2S_{xx} \right] \\
&= \frac{1}{\sigma^2} [2\hat{\beta}^2S_{xx} - \hat{\beta}^2S_{xx}] \\
&= \frac{\hat{\beta}^2S_{xx}}{\sigma^2} [2 - 1] \\
&= \frac{\hat{\beta}^2S_{xx}}{\sigma^2} = \xi_W
\end{aligned}$$

Então, de fato as estatísticas de Wald e de Razão de verossimilhanças são iguais.

1.2 Estatística de Escore

A estatística de escore não depende de se calcular os valores na função de verossimilhança, apenas sob a função escore, que é a derivada da função de verossimilhança. Para o caso de teste uniparamétrico a estatística tem a seguinte forma:

$$\xi_{SR} = \left[\hat{U}_\beta(\beta^0) \right]^2 \cdot \hat{\text{Var}}_0(\hat{\beta})$$

As funções escore para os parâmetros do modelo $\theta = (\alpha, \beta)^T$ podem ser obtidas por meio de forma matricial $U_\theta = [U_\alpha, U_\beta]^T = \sigma^{-2}X^T(y - \mu)$. Apresentação do desenvolvimento dessas expressões a seguir:

$$\begin{aligned}
U_\theta &= \sigma^{-2} \begin{bmatrix} 1 & \dots & 1 \\ x_1 & \dots & x_n \end{bmatrix} \begin{bmatrix} y_1 - \mu_1 \\ \vdots \\ y_n - \mu_n \end{bmatrix} \\
&= \sigma^{-2} \begin{bmatrix} \sum_{i=1}^n y_i - \mu_i \\ \sum_{i=1}^n x_i(y_i - \mu_i) \end{bmatrix}
\end{aligned}$$

Como explicado, só precisamos usar $U_\beta = \sigma^{-2} \sum_{i=1}^n x_i(y_i - \mu_i)$. É importante notar o seguinte fato:

$$\begin{aligned}
S_{xy} &= \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\
&= \sum_{i=1}^n x_i y_i - x_i \bar{y} - y_i \bar{x} + \bar{x} \bar{y} \\
&= \sum_{i=1}^n x_i y_i - x_i \bar{y} - \sum_{i=1}^n y_i \bar{x} + \bar{x} \bar{y} \\
&= \sum_{i=1}^n x_i y_i - x_i \bar{y} + \bar{x} \sum_{i=1}^n y_i - \bar{y} \\
&= \sum_{i=1}^n x_i y_i - x_i \bar{y} + 0 \\
&= \sum_{i=1}^n x_i (y_i - \bar{y})
\end{aligned}$$

Uma vez que a soma dos desvios das observações com relação à media é zero. Assim, sob H_0 , $\hat{\mu}_i \stackrel{H_0}{=} \alpha^0 \stackrel{H_0}{=} \bar{y}$ e então:

$$\begin{aligned}
\hat{U}_\beta(\beta^0) &= \sigma^{-2} \sum_{i=1}^n x_i (y_i - \mu_i) \\
&= \sigma^{-2} \sum_{i=1}^n x_i (y_i - \hat{\mu}) \\
&= \sigma^{-2} S_{xy}
\end{aligned}$$

A variância assintótica de β é a mesma que já apresentamos, e não há alterações nela, uma vez que não depende de parâmetros do modelo e σ^2 é conhecido. Assim $\text{Var}(\hat{\beta}) = \frac{\sigma^2}{S_{xx}}$. Assim a estatística de escore é dada por

$$\begin{aligned}
\xi_{SR} &= \left[\hat{U}_\beta(\beta^0) \right]^2 \cdot \text{Var}_0(\hat{\beta}) \\
&= \sigma^{-4} S_{xy}^2 \frac{\sigma^2}{S_{xx}} \\
&= \sigma^{-4} S_{xy}^2 \frac{\sigma^2 S_{xx}}{S_{xx} S_{xx}} \\
&= \sigma^{-2} \hat{\beta}^2 S_{xx}
\end{aligned}$$

$$= \frac{\hat{\beta}^2 S_{xx}}{\sigma^2} = \xi_W = \xi_{RV}$$

Mostrando a equivalência requisitada.

2 Exercício 2

O modelo apresentado pelo enunciado é o seguinte:

$$Y_{ij}|x_j \stackrel{\text{ind}}{\sim} \text{FE}(\mu_{ij}, \phi)$$

Com a parte sistemática dada por

$$g(\mu_{ij}) = \eta_{ij} = \alpha_i + \beta x_j$$

Com $i = 1, 2$ e $j = 1, \dots, r$. Note que esse modelo equivale à um modelo de retas paralelas com a mesma inclinação β . Pode-se para encontrar a estatística do teste de escore para testar $H_0 : \beta = 0$ contra $H_1 : \beta \neq 0$. Ou seja, iremos testar se as retas paralelas correspondentes aos grupos $i = 1$ e $i = 2$ são horizontais ou têm uma inclinação não nula.

A matriz modelo deste modelo é a seguinte. Note que as primeiras r linhas correspondem ao modelo quando $i = 1$ e as últimas r linhas quando $i = 2$.

$$X = \begin{bmatrix} 1 & 0 & x_1 \\ \vdots & \vdots & \vdots \\ 1 & 0 & x_r \\ 0 & 1 & x_1 \\ \vdots & \vdots & \vdots \\ 0 & 1 & x_r \end{bmatrix}_{2r \times 3}$$

Definamos os seguinte vetores para desenvolvermos a estatística de score:

$$\theta = \begin{bmatrix} \beta \\ \alpha_1 \\ \alpha_2 \\ \phi \end{bmatrix}, \quad \theta^0 = \begin{bmatrix} 0 \\ \alpha_1^0 \\ \alpha_2^0 \\ \phi_0 \end{bmatrix}$$

Onde θ corresponde ao vetor de parâmetros do modelo completo e θ^0 é o vetor de parâmetros proposto em H_0 . Assim, estatística de escore é a seguinte:

$$\xi_{SR} = \left[\hat{U}_\beta^0(\theta^0) \right]^T \hat{\text{Var}}_0(\hat{\beta}) \hat{U}_\beta^0(\theta^0)$$

$\hat{U}_\beta^0(\theta^0)$ é a função score associada ao parâmetro β do modelo proposto, calculada com as estimativas do modelo sob H_0 . $\hat{\text{Var}}_0(\hat{\beta})$ é a variância assintótica de $\hat{\beta}$ estimada sob H_0 .

2.1 Variância assintótica de $\hat{\beta}$

Iniciando pelo componente $\text{Var}(\hat{\beta})$. No caso dos MLGs em que se testam os parâmetros em modelos encaixados, como no nosso caso, podemos decompor a variância assintótica de $\hat{\beta}$ da seguinte maneira:

$$\text{Var}(\hat{\beta}) = \phi^{-1}(R^T W R)^{-1}$$

Com $R = X_1 - X_2 C$ e $C = (X_2^T W X_2)^{-1} X_2^T W X_1$. X_1 e X_2 são partições da matriz modelo X . Concretamente, elas têm a seguinte forma:

$$X_1 = \begin{bmatrix} x_1 \\ \vdots \\ x_r \\ x_1 \\ \vdots \\ x_r \end{bmatrix}_{2r \times 1} \quad X_2 = \begin{bmatrix} 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 0 & 1 \\ \vdots & \vdots \\ 0 & 1 \end{bmatrix}_{2r \times 2}$$

Note que C equivale ao vetor de parâmetros providas da regressão de X_2 em relação às colunas de X_1 . O cálculo de C é desenvolvido à seguir:

$$\begin{aligned} X_2^T W &= \begin{bmatrix} 1 & \dots & 1 & 0 & \dots & 0 \\ 0 & \dots & 0 & 1 & \dots & 1 \end{bmatrix} \cdot \text{diag} \{ \omega_{11}, \dots, \omega_{1r}, \omega_{21}, \dots, \omega_{2r} \} \\ &= \begin{bmatrix} \omega_{11} & \dots & \omega_{1r} & 0 & \dots & 0 \\ 0 & \dots & 0 & \omega_{21} & \dots & \omega_{2r} \end{bmatrix} \\ X_2^T W X_2 &= \begin{bmatrix} \omega_{11} & \dots & \omega_{1r} & 0 & \dots & 0 \\ 0 & \dots & 0 & \omega_{21} & \dots & \omega_{2r} \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 0 & 1 \\ \vdots & \vdots \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} \sum_{j=1}^r w_{1j} & 0 \\ 0 & \sum_{j=1}^r w_{2j} \end{bmatrix} \end{aligned}$$

E invertendo a matriz do resultado anterior

$$(X_2^T W X_2)^{-1} = \begin{bmatrix} \frac{1}{\sum_{j=1}^r w_{1j}} & 0 \\ 0 & \frac{1}{\sum_{j=1}^r w_{2j}} \end{bmatrix}$$

O segundo componente de C

$$X_2^T W X_1 = \begin{bmatrix} \omega_{11} & \dots & \omega_{1r} & 0 & \dots & 0 \\ 0 & \dots & 0 & \omega_{21} & \dots & \omega_{2r} \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ \vdots \\ x_r \\ x_1 \\ \vdots \\ x_r \end{bmatrix} = \begin{bmatrix} \sum_{j=1}^r x_j w_{1j} \\ \sum_{j=1}^r x_j w_{2j} \end{bmatrix}$$

Por fim

$$C = \begin{bmatrix} \frac{1}{\sum_{j=1}^r w_{1j}} & 0 \\ 0 & \frac{1}{\sum_{j=1}^r w_{2j}} \end{bmatrix} \cdot \begin{bmatrix} \sum_{j=1}^r x_j w_{1j} \\ \sum_{j=1}^r x_j w_{2j} \end{bmatrix} = \begin{bmatrix} \frac{\sum_{j=1}^r x_j w_{1j}}{\sum_{j=1}^r w_{1j}} \\ \frac{\sum_{j=1}^r x_j w_{2j}}{\sum_{j=1}^r w_{2j}} \end{bmatrix}$$

$$\begin{aligned} R &= X_1 - X_2 C \\ &= \begin{bmatrix} x_1 \\ \vdots \\ x_r \\ x_1 \\ \vdots \\ x_r \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 0 & 1 \\ \vdots & \vdots \\ 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} \frac{\sum_{j=1}^r x_j w_{1j}}{\sum_{j=1}^r w_{1j}} \\ \frac{\sum_{j=1}^r x_j w_{2j}}{\sum_{j=1}^r w_{2j}} \end{bmatrix} \\ &= \begin{bmatrix} x_1 - \frac{\sum_{j=1}^r x_j w_{1j}}{\sum_{j=1}^r w_{1j}} \\ \vdots \\ x_r - \frac{\sum_{j=1}^r x_j w_{1j}}{\sum_{j=1}^r w_{1j}} \\ x_1 - \frac{\sum_{j=1}^r x_j w_{2j}}{\sum_{j=1}^r w_{2j}} \\ \vdots \\ x_r - \frac{\sum_{j=1}^r x_j w_{2j}}{\sum_{j=1}^r w_{2j}} \end{bmatrix} \end{aligned}$$

Para o cálculo da variância assintótica $\text{Var}(\hat{\beta})$ sob H_0 , $\text{Var}_0(\hat{\beta})$, escrevemos os componentes respeitando as restrições testadas, $\text{Var}_0(\hat{\beta}) = \phi_0^{-1}(R_0^T W_0 R_0)^{-1}$. Nessas condições, a parte sistemática, os pesos, e os elementos de R podem ser escritos como:

$$\eta_{ij} = \alpha_i + \beta x_j \xrightarrow{H_0: \beta=0} \eta_i = \alpha_i^0$$

$$\omega_{ij} \xrightarrow{H_0: \beta=0} \omega_i^0$$

$$R = \left(x_j - \frac{\sum_{j=1}^r x_j w_{2j}}{\sum_{j=1}^r w_{2j}} \right)_{2r \times 1} \xrightarrow{H_0: \beta=0} R_0 = (x_j - \bar{x})_{2r \times 1}$$

$$W = \text{diag} \{ \omega_{11}, \dots, \omega_{1r}, \omega_{21}, \dots, \omega_{2r} \} \xrightarrow{H_0: \beta=0} W_0 = \text{diag} \{ \omega_1^0, \dots, \omega_1^0, \omega_2^0, \dots, \omega_2^0 \}$$

E a variância assintótica é desenvolvida a partir dos seguintes componentes:

$$\begin{aligned} R_0^T W_0 &= \begin{bmatrix} x_1 - \bar{x} & \dots & x_r - \bar{x} & x_1 - \bar{x} & \dots & x_r - \bar{x} \end{bmatrix} \cdot \text{diag} \{ \omega_1^0, \dots, \omega_1^0, \omega_2^0, \dots, \omega_2^0 \} \\ &= \begin{bmatrix} \omega_1^0(x_1 - \bar{x}) & \dots & \omega_1^0(x_r - \bar{x}) & \omega_2^0(x_1 - \bar{x}) & \dots & \omega_2^0(x_r - \bar{x}) \end{bmatrix} \end{aligned}$$

$$\begin{aligned}
R_0^T W_0 R_0 &= \begin{bmatrix} \omega_1^0(x_1 - \bar{x}) & \dots & \omega_1^0(x_r - \bar{x}) & \omega_2^0(x_1 - \bar{x}) & \dots & \omega_2^0(x_r - \bar{x}) \end{bmatrix} \cdot \begin{bmatrix} x_1 - \bar{x} \\ \vdots \\ x_r - \bar{x} \\ x_1 - \bar{x} \\ \vdots \\ x_r - \bar{x} \end{bmatrix} \\
&= \omega_1^0(x_1 - \bar{x})^2 + \dots + \omega_1^0(x_r - \bar{x})^2 + \omega_2^0(x_1 - \bar{x})^2 + \dots + \omega_2^0(x_r - \bar{x})^2 \\
&= \omega_1^0 \sum_{j=1}^r (x_j - \bar{x})^2 + \omega_2^0 \sum_{j=1}^r (x_j - \bar{x})^2 \\
&= (\omega_1^0 + \omega_2^0) \sum_{j=1}^r (x_j - \bar{x})^2
\end{aligned}$$

Resultando nas seguintes expressões. A segunda mostra as estimativas necessárias para se estimar a variância assintótica de $\hat{\beta}$:

$$\begin{aligned}
\text{Var}_0(\hat{\beta}) &= \phi_0^{-1} (R_0^T W_0 R_0)^{-1} = \left(\phi_0 (\omega_1^0 + \omega_2^0) \sum_{j=1}^r (x_j - \bar{x})^2 \right)^{-1} \\
\hat{\text{Var}}_0(\hat{\beta}) &= \left(\hat{\phi}_0 (\hat{\omega}_1^0 + \hat{\omega}_2^0) \sum_{j=1}^r (x_j - \bar{x})^2 \right)^{-1}
\end{aligned}$$

2.2 Função score U_β

A função score é definida como $U_\beta(\theta) = \phi X_1^T W^{1/2} V^{-1/2} (\mathbf{y} - \mu)$. Porém podemos reescrevê-la em função do resíduo de Pearson $r_p = \phi^{1/2} V^{-1/2} (\mathbf{y} - \mu)$ e $U_\beta(\theta) = \phi^{1/2} X_1^T W^{1/2} r_p$

Iniciaremos o cálculo por $X_1^T W^{1/2}$:

$$\begin{aligned}
X_1^T W^{1/2} &= \begin{bmatrix} x_1 & \dots & x_r & x_1 & \dots & x_r \end{bmatrix} \cdot \text{diag} \{ \sqrt{\omega_{11}}, \dots, \sqrt{\omega_{1r}}, \sqrt{\omega_{21}}, \dots, \sqrt{\omega_{2r}} \} \\
&= \begin{bmatrix} x_1 \sqrt{\omega_{11}} & \dots & x_r \sqrt{\omega_{1r}} & x_1 \sqrt{\omega_{21}} & \dots & x_r \sqrt{\omega_{2r}} \end{bmatrix}
\end{aligned}$$

Utilizando o resíduo de Pearson por obsevação, ficamos com:

$$\begin{aligned}
X_1^T W^{1/2} r_p &= \begin{bmatrix} x_1 \sqrt{\omega_{11}} & \dots & x_r \sqrt{\omega_{1r}} & x_1 \sqrt{\omega_{21}} & \dots & x_r \sqrt{\omega_{2r}} \end{bmatrix} \cdot \begin{bmatrix} r_{11} \\ \vdots \\ r_{1r} \\ r_{21} \\ \vdots \\ r_{2r} \end{bmatrix} \\
&= \sum_{j=1}^r x_j \sqrt{\omega_{1j}} r_{1j} + \sum_{j=1}^r x_j \sqrt{\omega_{2j}} r_{2j}
\end{aligned}$$

Onde $r_{ij} = \frac{\phi^{1/2}(y_{ij} - \mu_{ij})}{\sqrt{V_{ij}}}$. Assim o elemento da soma de cada um dos grupos, quando o resíduo é desmembrado:

$$x_j \sqrt{\omega_{ij}} r_{ij} = \frac{x_j \sqrt{\omega_{ij}} \phi^{1/2} (y_{ij} - \mu_{ij})}{\sqrt{V_{ij}}} \quad (1)$$

Nesse estágio do desenvolvimento da estatística de escore, precisamos assumir que a ligação utilizada no modelo de retas paralelas proposto é canônica. A razão disso é a seguinte: como os pesos são definidos como $\omega_{ij} = \left(\frac{d\mu_{ij}}{d\eta_{ij}} \right)^2 V_i^{-1}$. Se a ligação for canônica $\eta_{ij} = \theta_{ij}$, ou seja o componente linear sistemático coincide com o parâmetro canônico da família exponencial. Assim $\omega_{ij} = \left(\frac{d\mu_{ij}}{d\theta_{ij}} \right)^2 V_i^{-1}$ e, pela propriedade da família exponencial, $\frac{d\mu_{ij}}{d\theta_{ij}} = V_{ij}$. Por fim, os pesos sob a ligação canônica são expressos pela seguinte forma amigável $\omega_{ij} = V_{ij}^2 V_{ij}^{-1} = V_{ij}$.

Com isso, os pesos/variâncias dos componentes da soma na função escore de U_β descritos em (1) se cancelam quando a ligação do modelo é canônica:

$$x_j \sqrt{\omega_{ij}} r_{ij} = \frac{x_j \sqrt{\omega_{ij}} \phi^{1/2} (y_{ij} - \mu_{ij})}{\sqrt{V_{ij}}} \quad (2)$$

$$= \frac{x_j \sqrt{\omega_{ij}} \phi^{1/2} (y_{ij} - \mu_{ij})}{\sqrt{\omega_{ij}}} \quad (3)$$

$$= \phi^{1/2} x_j (y_{ij} - \mu_{ij}) \quad (4)$$

E a função escore possui então a seguinte forma:

$$\begin{aligned} U_\beta(\theta) &= \phi^{1/2} \left[\sum_{j=1}^r \phi^{1/2} x_j (y_{1j} - \mu_{1j}) + \sum_{j=1}^r \phi^{1/2} x_j (y_{2j} - \mu_{2j}) \right] \\ &= \phi \left[\sum_{j=1}^r x_j (y_{1j} - \mu_{1j}) + \sum_{j=1}^r x_j (y_{2j} - \mu_{2j}) \right] \end{aligned}$$

O próximo passo é entender como os componentes de $U_\beta(\theta)$ deveriam ser escritos sob H_0 , ou seja, qual forma de $U_\beta(\theta^0)$. Como já expomos anteriormente, no cálculo da variância assintótica de $\hat{\beta}$:

$$\eta_{ij} = \alpha_i + \beta x_j \xrightarrow{H_0: \beta=0} \eta_i = \alpha_i^0$$

Adicionalmente, ainda sob H_0 temos

$$\mu_{ij} = g^{-1}(\eta_{ij}) \xrightarrow{H_0: \beta=0} \mu_i^0 = g^{-1}(\alpha_i^0) = \bar{y}_i$$

Portanto, o vetor de parâmetros θ sob a hipótese nula é:

$$\theta = \begin{bmatrix} \beta \\ \alpha_1 \\ \alpha_2 \\ \phi \end{bmatrix} \xrightarrow{H_0: \beta=0} \theta^0 = \begin{bmatrix} 0 \\ \bar{y}_1 \\ \bar{y}_2 \\ \phi_0 \end{bmatrix}$$

Culminando na seguinte função escore estimada:

$$\begin{aligned}
U_\beta(\theta) &= \phi \left[\sum_{j=1}^r x_j(y_{1j} - \mu_{1j}) + \sum_{j=1}^r x_j(y_{2j} - \mu_{2j}) \right] \\
&\downarrow \\
\hat{U}_\beta(\theta^0) &= \hat{\phi}_0 \left[\sum_{j=1}^r x_j(y_{1j} - \bar{y}_1) + \sum_{j=1}^r x_j(y_{2j} - \bar{y}_2) \right]
\end{aligned}$$

2.3 Estatística escore

Como estamos testando apenas um parâmetro, a estatística de escore resultante é a seguinte

$$\begin{aligned}
\xi_{SR} &= \left[\hat{U}_\beta^0(\theta^0) \right]^T \hat{\text{Var}}_0(\hat{\beta}) \hat{U}_\beta^0(\theta^0) \\
&= \left[\hat{U}_\beta^0(\theta^0) \right]^2 \hat{\text{Var}}_0(\hat{\beta})
\end{aligned}$$

Juntando os componentes calculados nas seções anteriores, nomeadamente, a função escore e a variância assintótica, ambas para o parâmetro β e estimadas sob a hipótese nula. Vamos reproduzir ambas a seguir:

$$\begin{aligned}
\hat{U}_\beta(\theta^0) &= \hat{\phi}_0 \left[\sum_{j=1}^r x_j(y_{1j} - \bar{y}_1) + \sum_{j=1}^r x_j(y_{2j} - \bar{y}_2) \right] \\
\hat{\text{Var}}_0(\hat{\beta}) &= \left(\hat{\phi}_0(\hat{\omega}_1^0 + \hat{\omega}_2^0) \sum_{j=1}^r (x_j - \bar{x})^2 \right)^{-1}
\end{aligned}$$

Finalmente, a expressão da algébrica estatística de escore é:

$$\begin{aligned}
\xi_{SR} &= \frac{\left(\hat{\phi}_0 \left[\sum_{j=1}^r x_j(y_{1j} - \bar{y}_1) + \sum_{j=1}^r x_j(y_{2j} - \bar{y}_2) \right] \right)^2}{\hat{\phi}_0(\hat{\omega}_1^0 + \hat{\omega}_2^0) \sum_{j=1}^r (x_j - \bar{x})^2} \\
&= \frac{\hat{\phi}_0 \left[\sum_{j=1}^r x_j(y_{1j} - \bar{y}_1) + \sum_{j=1}^r x_j(y_{2j} - \bar{y}_2) \right]^2}{(\hat{\omega}_1^0 + \hat{\omega}_2^0) \sum_{j=1}^r (x_j - \bar{x})^2}
\end{aligned}$$

Que de fato é a forma apresentada no enunciado. Note que, por usarmos a ligação canônica nos para se alcançar os resultados, a notação ω_i^0 pode ser substituída por V_i^0 , uma vez que eles são iguais sob essas condições.

3 Exercício 3

A função densidade de uma variável $Y_i \stackrel{\text{iid}}{\sim} \text{NI}(\mu, \phi)$ tem a seguinte forma:

$$\frac{\phi^{1/2}}{\sqrt{2\pi y^3}} \exp \left[-\frac{\phi(y - \mu)^2}{2\mu^2 y} \right]$$

O enunciado pede que apresentemos a estatística da razão de verossimilhanças para testar a hipótese $H_0 : \phi = 1$ contra $H_1 : \phi \neq 1$. Assumo que o parâmetro μ é desconhecido, e por isso será necessário estimá-lo por máxima verossimilhança. O teste de razão de verossimilhança é dado pela seguinte expressão:

$$\xi_{RV} = 2(L(y_i; \hat{\mu}, \hat{\phi}) - L(y_i; \hat{\mu}, 1))$$

Para tanto, utilizaremos a forma da função de densidade que além de provar que Y_i pertence à família exponencial, também facilita um pouco as computações:

$$\exp \left[\phi \left(-\frac{y}{2\mu^2} + \frac{1}{\mu} \right) - \frac{1}{2} \left[\log(2\pi y^3/\phi) + \frac{\phi}{y} \right] \right]$$

As computações a seguir a função de verossimilhança que usa função de densidade apresentada. Já partindo do seu logarítmo, temos

$$\begin{aligned} L(y_i; \mu, \phi) &= \sum_{i=1}^n \left[\phi \left(-\frac{y_i}{2\mu^2} + \frac{1}{\mu} \right) - \frac{1}{2} \left[\log(2\pi y_i^3/\phi) + \frac{\phi}{y_i} \right] \right] \\ &= \sum_{i=1}^n \left[\phi \left(\frac{2\mu - y_i}{2\mu^2} \right) - \frac{1}{2} \left[\log(2\pi y_i^3/\phi) + \frac{\phi}{y_i} \right] \right] \\ &= \frac{\phi}{2\mu^2} \left(2n\mu - \sum_{i=1}^n y_i \right) - \frac{1}{2} \sum_{i=1}^n \log(2\pi y_i^3) + \frac{n \log(\phi)}{2} - \frac{\phi}{2} \sum_{i=1}^n \frac{1}{y_i} \end{aligned}$$

Derivando com relação ao parâmetro μ , obtemos a função score do parâmetro

$$\begin{aligned} \frac{\partial L}{\partial \mu} &= \frac{\phi - 2}{2} \frac{1}{\mu^3} \left(2n\mu - \sum_{i=1}^n y_i \right) + \frac{2n\phi}{2\mu^2} \\ &= -\frac{\phi}{\mu^3} \left(2n\mu - \sum_{i=1}^n y_i \right) + \frac{n\phi}{\mu^2} \end{aligned}$$

Igualando a zero a expressão anterior, chegamos na estimativa de máxima verossimilhança para μ :

$$\begin{aligned} \frac{\partial L}{\partial \mu} &= 0 && \Leftrightarrow \\ -\frac{\phi}{\mu^3} \left(2n\mu - \sum_{i=1}^n y_i \right) + \frac{n\phi}{\mu^2} &= 0 && \Leftrightarrow \\ -\frac{(2n\mu - \sum_{i=1}^n y_i)}{\mu^3} + \frac{n\mu}{\mu^2\mu} &= 0 && \Leftrightarrow \\ -2n\mu + \sum_{i=1}^n y_i + n\mu &= 0 && \Leftrightarrow \\ \sum_{i=1}^n y_i - n\mu &= 0 && \Leftrightarrow \\ \hat{\mu} = \frac{1}{n} \sum_{i=1}^n y_i &= \bar{y} \end{aligned}$$

O próximo passo é calcular uma expressão para a função de verossimilhança quando as estimativas estão sob o modelo proposto (em H_0 e H_1). Calcularemos primeiro $L(y_i; \hat{\mu}, \hat{\phi})$:

$$L(y_i; \hat{\mu}, \hat{\phi}) = \sum_{i=1}^n \left[\hat{\phi} \left(-\frac{y_i}{2\hat{\mu}^2} + \frac{1}{\hat{\mu}} \right) - \frac{1}{2} \left[\log(2\pi y_i^3 / \hat{\phi}) + \frac{\hat{\phi}}{y_i} \right] \right] \quad (1)$$

Antes de reduzirmos a expressão de $L(y_i; \hat{\mu}, \hat{\phi})$, iremos reescrever o fator que multiplica o primeiro ϕ de maneira conveniente. Note que omitimos o subscrito i e a notação que indica estimativas para mantermos clareza nas manipulações:

$$\begin{aligned} -\frac{y}{2\mu^2} + \frac{1}{\mu} &= \frac{-y + 2\mu(-y)}{2\mu^2(-y)} \\ &= -\frac{y^2 - 2\mu y + \mu^2 - \mu^2}{2\mu^2 y} \\ &= (-1) \left[\frac{(y - \mu)^2}{2\mu^2 y} - \frac{\mu^2}{2\mu^2 y} \right] \\ &= -\frac{(y - \mu)^2}{2\mu^2 y} + \frac{1}{2y} \end{aligned}$$

Desta maneira podemos escrever (1) da seguinte forma:

$$L(y_i; \hat{\mu}, \hat{\phi}) = \sum_{i=1}^n \left[\hat{\phi} \left(-\frac{(y_i - \hat{\mu})^2}{2\hat{\mu}^2 y_i} + \frac{1}{2y_i} \right) - \frac{1}{2} \left[\log(2\pi y_i^3 / \hat{\phi}) + \frac{\hat{\phi}}{y_i} \right] \right]$$

Desenvolvendo os somatórios temos:

$$\begin{aligned} L(y_i; \hat{\mu}, \hat{\phi}) &= \sum_{i=1}^n \left[\hat{\phi} \left(-\frac{(y_i - \hat{\mu})^2}{2\hat{\mu}^2 y_i} + \frac{1}{2y_i} \right) - \frac{1}{2} \left[\log(2\pi y_i^3 / \hat{\phi}) + \frac{\hat{\phi}}{y_i} \right] \right] \\ &= -\frac{\hat{\phi}}{2} \sum_{i=1}^n \frac{(y_i - \hat{\mu})^2}{\hat{\mu}^2 y_i} + \frac{\hat{\phi}}{2} \sum_{i=1}^n \frac{1}{y_i} - \frac{1}{2} \sum_{i=1}^n \log(2\pi y_i^3) + \frac{n \log(\hat{\phi})}{2} - \frac{\hat{\phi}}{2} \sum_{i=1}^n \frac{1}{y_i} \\ &= \frac{n \log(\hat{\phi})}{2} - \frac{\hat{\phi}}{2} \sum_{i=1}^n \frac{(y_i - \hat{\mu})^2}{\hat{\mu}^2 y_i} - \frac{1}{2} \sum_{i=1}^n \log(2\pi y_i^3) \end{aligned} \quad (2)$$

Note que, para o caso de uma variável aleatória distribuída por uma Normal Inversa, a função desvio é dada por

$$D(\mathbf{y}, \hat{\mu}) = \sum_{i=1}^n \frac{(y_i - \hat{\mu})^2}{\hat{\mu}^2 y_i}$$

Assim, podemos reescrever (2)

$$\begin{aligned} L(y_i; \hat{\mu}, \hat{\phi}) &= \frac{n \log(\hat{\phi})}{2} - \frac{\hat{\phi}}{2} \sum_{i=1}^n \frac{(y_i - \hat{\mu})^2}{\hat{\mu}^2 y_i} - \frac{1}{2} \sum_{i=1}^n \log(2\pi y_i^3) \\ &= \frac{n \log(\hat{\phi})}{2} - \frac{\hat{\phi}}{2} D(\mathbf{y}, \hat{\mu}) - \frac{1}{2} \sum_{i=1}^n \log(2\pi y_i^3) \end{aligned}$$

Assim, podemos partir para o cálculo de ξ_{RV} a partir de sua definição e substituindo os casos particulares de H_0 e H_1 :

$$\begin{aligned}
\xi_{RV} &= 2(L(y_i; \hat{\mu}, \hat{\phi}) - L(y_i; \hat{\mu}, 1)) \\
&= 2 \left[\frac{n \log(\hat{\phi})}{2} - \frac{\hat{\phi}}{2} D(\mathbf{y}, \hat{\mu}) - \frac{1}{2} \sum_{i=1}^n \log(2\pi y_i^3) - \left(\frac{n \log(1)}{2} - \frac{1}{2} D(\mathbf{y}, \hat{\mu}) - \frac{1}{2} \sum_{i=1}^n \log(2\pi y_i^3) \right) \right] \quad (3) \\
&= n \log(\hat{\phi}) - \hat{\phi} D(\mathbf{y}, \hat{\mu}) + D(\mathbf{y}, \hat{\mu})
\end{aligned}$$

Porém, nos é fornecido no enunciado que $\hat{\phi} = \frac{n}{D(\mathbf{y}, \hat{\mu})}$, levando ao fato que $D(\mathbf{y}, \hat{\mu}) = n\hat{\phi}^{-1}$. Munidos disso, podemos desenvolver (3) ainda mais:

$$\begin{aligned}
\xi_{RV} &= n \log(\hat{\phi}) - \hat{\phi} D(\mathbf{y}, \hat{\mu}) + D(\mathbf{y}, \hat{\mu}) \\
&= n \log(\hat{\phi}) - \hat{\phi} \hat{\phi}^{-1} n + n \hat{\phi}^{-1} \\
&= n \log(\hat{\phi}) + n(\hat{\phi}^{-1} - 1)
\end{aligned}$$

Que é o resultado requisitado pelo enunciado.

4 Exercício 4

O modelo proposto no enunciado consiste em $Y_{ij} \stackrel{ind}{\sim} \text{Poisson}(\mu_{ij})$ para $i, j = 1, 2$. O componente sistemático do modelo é

$$\log(\mu_{ij}) = \alpha + \beta_i + \gamma_j + \delta_{ij}$$

Onde, para permitir a identificabilidade do modelo, temos $\beta_1 = \gamma_1 = 0$ e $\delta_{11} = \delta_{12} = \delta_{21} = 0$ e $\delta_{22} = \delta$. Onde β_1 e β_2 correspondem aos efeitos do fator A e γ_1 e γ_2 correspondem aos efeitos do fator B.

4.1 Modelo Multinomial

Com relação aos fatores A e B, e seus respectivos níveis, A_1 e A_2 (correspondentes à $i = 1, 2$) e B_1 e B_2 (correspondentes à $j = 1, 2$), podemos pensar no modelo proposto para Y_{ij} como a tabela de contingência 2x2 a seguir.

		A	
		A_1	A_2
B	B_1	Y_{11}	Y_{21}
	B_2	Y_{12}	Y_{22}

E as partes sistemáticas associadas à cada uma dessas combinações de fatores, quando substituimos as restrições do impostas pela identificabilidade do modelo, ficam dadas por

$$\log(\mu_{11}) = \alpha$$

$$\log(\mu_{12}) = \alpha + \gamma_2$$

$$\log(\mu_{21}) = \alpha + \beta_2$$

$$\log(\mu_{22}) = \alpha + \beta_2 + \gamma_2 + \delta$$

Com essa especificação do modelo Poisson em termos dos fatores A e B, se condicionarmos o problema em $n = \sum_{i=1}^2 \sum_{j=1}^2 Y_{ij}$, temos que

$$\mathbf{Y} \sim \text{Multinomial}(n, \boldsymbol{\pi})$$

Com $\mathbf{Y} = (Y_{11}, Y_{12}, Y_{21}, Y_{22})^T$ e $\boldsymbol{\pi} = (\pi_{11}, \pi_{12}, \pi_{21}, \pi_{22})$. Onde π_{ij} é, quando em função das médias de Y_{ij} , dado por

$$\pi_{ij} = \frac{\mu_{ij}}{\sum_{i=1}^2 \sum_{j=1}^2 \mu_{ij}}$$

E em seguida, mostramos a expressão de π_{ij} em termos das partes sistemática que englobam os efeitos dos fatores A e B:

$$\pi_{ij} = \frac{e^{\alpha + \beta_i + \gamma_j + \delta_{ij}}}{\sum_{i=1}^2 \sum_{j=1}^2 e^{\alpha + \beta_i + \gamma_j + \delta_{ij}}} \quad (1)$$

4.2 Independência probabilística entre os fatores

Partindo da tabela de contingência apresentada na seção anterior e condicionados à $n = \sum_{i=1}^2 \sum_{j=1}^2 Y_{ij}$ podemos construir a seguinte tabela de contingência relativa entre os fatores A e B

		A		Marginal
		A_1	A_2	B
B	B_1	π_{11}	π_{21}	π_{+1}
	B_2	π_{12}	π_{22}	π_{+2}
Marginal	A	π_{1+}	π_{2+}	1

Adicionamos margens à tabela, que correspondem às distribuições marginais dos fatores. Além disso $\pi_{i+} = \sum_{j=1}^2 \pi_{ij}$ e $\pi_{+j} = \sum_{i=1}^2 \pi_{ij}$.

Pede-se para mostrar que a independência probabilística entre os fatores A e B ocorre quando $\delta_{22} = \delta = 0$. Mostrar a independência probabilística nesse contexto implica em mostrar que

$$\pi_{ij} = \pi_{i+} \cdot \pi_{+j} \quad \forall i, j = 1, 2$$

Ou, em outras palavras, equivale à mostrar com o produtos das distribuições marginais coincide com a probabilidade conjunta para todas as combinações de níveis entre A e B. Mostraremos cada um dos pares $i, j = 1, 2$, porém antes precisamos levar as expressões de π_{ij} , definidas em (1), para versões mais amigáveis. Primeiro vamos nos livrar do intercepto dos modelos poisson, uma vez que a equivalência entre os modelos multinomial e poisson só se dá às variáveis dentro do modelo, e as equivalências entre interceptos não é relevante para o que queremos mostrar:

$$\begin{aligned}
 \pi_{ij} &= \frac{e^{\alpha + \beta_i + \gamma_j + \delta_{ij}}}{\sum_{i=1}^2 \sum_{j=1}^2 e^{\alpha + \beta_i + \gamma_j + \delta_{ij}}} \\
 &= \frac{e^{\alpha} e^{\beta_i + \gamma_j + \delta_{ij}}}{e^{\alpha} \sum_{i=1}^2 \sum_{j=1}^2 e^{\beta_i + \gamma_j + \delta_{ij}}} \\
 &= \frac{e^{\beta_i + \gamma_j + \delta_{ij}}}{\sum_{i=1}^2 \sum_{j=1}^2 e^{\beta_i + \gamma_j + \delta_{ij}}} \tag{2}
 \end{aligned}$$

Em seguida, manipulamos o denominador de (2), uma vez que ele é comum à todos os π_{ij}

$$\sum_{i=1}^2 \sum_{j=1}^2 e^{\beta_i + \gamma_j + \delta_{ij}} = 1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2 + \delta}$$

E então podemos chegar às expressões de cada π_{ij} :

$$\begin{aligned}
 \pi_{11} &= \frac{1}{1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2 + \delta}} \\
 \pi_{12} &= \frac{e^{\beta_2}}{1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2 + \delta}}
 \end{aligned}$$

$$\pi_{21} = \frac{e^{\gamma_2}}{1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2 + \delta}}$$

$$\pi_{22} = \frac{e^{\beta_2 + \gamma_2 + \delta}}{1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2 + \delta}}$$

4.2.1 $\pi_{11} = \pi_{1+} \cdot \pi_{+1}$

$$\begin{aligned} \pi_{1+} \cdot \pi_{+1} &= (\pi_{11} + \pi_{12}) \cdot (\pi_{11} + \pi_{21}) \\ &= \frac{(1 + e^{\gamma_2})(1 + e^{\beta_2})}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2 + \delta})^2} \\ &= \frac{1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2}}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2 + \delta})^2} \end{aligned}$$

Se $\delta = 0$:

$$\begin{aligned} \pi_{1+} \cdot \pi_{+1} &= \frac{1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2}}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2})^2} \\ &= \frac{1}{1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2}} \\ &= \pi_{11} \end{aligned}$$

4.2.2 $\pi_{12} = \pi_{1+} \cdot \pi_{+2}$

$$\begin{aligned} \pi_{1+} \cdot \pi_{+2} &= (\pi_{11} + \pi_{12}) \cdot (\pi_{12} + \pi_{22}) \\ &= \frac{(1 + e^{\gamma_2})(e^{\gamma_2} + e^{\beta_2 + \gamma_2 + \delta})}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2 + \delta})^2} \\ &= \frac{e^{\gamma_2} + e^{\beta_2 + \gamma_2 + \delta} + e^{\gamma_2} e^{\gamma_2} + e^{\gamma_2} e^{\beta_2 + \gamma_2 + \delta}}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2 + \delta})^2} \\ &= \frac{e^{\gamma_2} (1 + e^{\gamma_2} + e^{\beta_2 + \delta} + e^{\beta_2 + \gamma_2 + \delta})}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2 + \delta})^2} \end{aligned}$$

Tomando $\delta = 0$:

$$\begin{aligned} \pi_{1+} \cdot \pi_{+2} &= \frac{e^{\gamma_2} (1 + e^{\gamma_2} + e^{\beta_2} + e^{\beta_2 + \gamma_2})}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2})^2} \\ &= \frac{e^{\gamma_2}}{1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2}} \\ &= \pi_{12} \end{aligned}$$

4.2.3 $\pi_{21} = \pi_{2+} \cdot \pi_{+1}$

$$\begin{aligned} \pi_{2+} \cdot \pi_{+1} &= (\pi_{21} + \pi_{22}) \cdot (\pi_{11} + \pi_{21}) \\ &= \frac{(e^{\beta_2} + e^{\beta_2 + \gamma_2 + \delta})(1 + e^{\beta_2})}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2 + \gamma_2 + \delta})^2} \end{aligned}$$

$$\begin{aligned}
&= \frac{e^{\beta_2} + e^{\beta_2}e^{\beta_2} + e^{\beta_2+\gamma_2+\delta} + e^{\beta_2}e^{\beta_2+\gamma_2+\delta}}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2+\gamma_2+\delta})^2} \\
&= \frac{e^{\beta_2} (1 + e^{\gamma_2} + e^{\gamma_2+\delta} + e^{\beta_2+\gamma_2+\delta})}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2+\gamma_2+\delta})^2}
\end{aligned}$$

Com $\delta = 0$:

$$\begin{aligned}
\pi_{2+} \cdot \pi_{+1} &= \frac{e^{\beta_2} (1 + e^{\gamma_2} + e^{\gamma_2} + e^{\beta_2+\gamma_2})}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2+\gamma_2})^2} \\
&= \frac{e^{\beta_2}}{1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2+\gamma_2}} \\
&= \pi_{21}
\end{aligned}$$

4.2.4 $\pi_{22} = \pi_{2+} \cdot \pi_{+2}$

$$\begin{aligned}
\pi_{2+} \cdot \pi_{+2} &= (\pi_{21} + \pi_{22}) \cdot (\pi_{12} + \pi_{22}) \\
&= \frac{(e^{\beta_2} + e^{\beta_2+\gamma_2+\delta})(e^{\gamma_2} + e^{\beta_2+\gamma_2+\delta})}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2+\gamma_2+\delta})^2} \\
&= \frac{e^{\beta_2}e^{\gamma_2} + e^{\beta_2}e^{\beta_2+\gamma_2+\delta} + e^{\gamma_2}e^{\beta_2+\gamma_2+\delta} + e^{\beta_2}e^{\beta_2+\gamma_2+\delta} + e^{2(\beta_2+\gamma_2+\delta)}}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2+\gamma_2+\delta})^2} \\
&= \frac{e^{\beta_2+\gamma_2+\delta} (e^{-\delta} + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2+\gamma_2+\delta})}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2+\gamma_2+\delta})^2}
\end{aligned}$$

Impondo $\delta = 0$:

$$\begin{aligned}
\pi_{2+} \cdot \pi_{+2} &= \frac{e^{\beta_2+\gamma_2} (1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2+\gamma_2})}{(1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2+\gamma_2})^2} \\
&= \frac{e^{\beta_2+\gamma_2}}{1 + e^{\beta_2} + e^{\gamma_2} + e^{\beta_2+\gamma_2}} \\
&= \pi_{22}
\end{aligned}$$

Provando assim que se $\delta = 0$, $\pi_{ij} = \pi_{i+} \cdot \pi_{+j} \quad \forall i, j = 1, 2$ e os fatores A e B são probabilisticamente independentes.

5 Exercício 5

O modelo descrito pelo enunciado consiste em $Y_{ij}|z_i \stackrel{ind}{\sim} \text{FE}(\mu, \phi_i)$ com $i = 1, 2$ e $j = 1, \dots, m$. A parte sistemática é:

$$\log(\phi_1) = \lambda_1 = \alpha - \beta$$

$$\log(\phi_2) = \lambda_2 = \alpha + \beta$$

5.1 Função Escore U_β

Desejamos encontrar uma forma algébrica fechada para a estatística de escore que testa as hipóteses $H_0 : \beta = 0$ contra $H_1 : \beta \neq 0$. A estatística de score para o nosso conjunto de hipóteses tem a seguinte forma:

$$\xi_{SR} = \left(\hat{U}_\beta(\hat{\beta}^0) \right)^2 \hat{\text{Var}}_0(\hat{\beta})$$

Iremos calcular cada um desses componentes de maneira genérica e em seguida avaliá-los sob as restrições das hipóteses testadas. Como se trata de hipóteses com relação ao parâmetro de precisão de uma variável pertencente à família exponencial, vamos trabalhar com a verossimilhança restrita da variável $T_{ij} = t_{ij}$, onde $t_{ij} = y_{ij}\theta - b(\theta) + u(y_{ij})$, onde as estimativas do parâmetro de localização θ e suas funções partirão de um modelo apenas com intercepto.

Assim, a derivação da função escore U_β será com base na função de verossimilhança da variável transformada T_{ij} .

$$L(t_{ij}; \phi_i) = \sum_{i=1}^2 \sum_{j=1}^m \phi_i t_{ij} + d(\phi_i) + u(y_{ij})$$

$$\begin{aligned} U_\beta &= \frac{\partial L}{\partial \beta} \\ &= \frac{\partial}{\partial \beta} \sum_{i=1}^2 \sum_{j=1}^m \phi_i t_{ij} + d(\phi_i) + u(y_{ij}) \\ &= \sum_{i=1}^2 \sum_{j=1}^m \frac{\partial}{\partial \beta} [\phi_i t_{ij} + d(\phi_i) + u(y_{ij})] \\ &= \sum_{i=1}^2 \sum_{j=1}^m \left[\frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \beta} t_{ij} + d'(\phi_i) \frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \beta} \right] \end{aligned} \tag{1}$$

Onde das derivadas em (1) são:

$$\frac{d\phi_i}{d\lambda_i} = \left(\frac{d\lambda_i}{d\phi_i} \right)^{-1} = \left(\frac{d}{d\phi_i} \log(\phi_i) \right)^{-1} = \left(\frac{1}{\phi_i} \right)^{-1} = \phi_i$$

$$\lambda_1 = \alpha - \beta \quad \rightarrow \quad \frac{\partial \lambda_1}{\partial \beta} = -1 \quad \lambda_2 = \alpha + \beta \quad \rightarrow \quad \frac{\partial \lambda_2}{\partial \beta} = 1$$

Onde denotaremos que, simbolicamente, $\frac{\partial \lambda_i}{\partial \beta} = (-1)^i$, por conveniência. Então, a função escore do parâmetro β é

$$\begin{aligned}
U_\beta &= \sum_{i=1}^2 \sum_{j=1}^m \left[\frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \beta} t_{ij} + d'(\phi_i) \frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \beta} \right] \\
&= \sum_{i=1}^2 \sum_{j=1}^m \left[\phi_i (-1)^i t_{ij} + \phi_i (-1)^i d'(\phi_i) \right] \\
&= \sum_{i=1}^2 \sum_{j=1}^m \phi_i (-1)^i [t_{ij} + d'(\phi_i)]
\end{aligned}$$

5.2 Variância assintótica de $\hat{\beta}$

Em seguida, calculamos o componente da hessiana de L referente à β

$$\begin{aligned}
\frac{\partial^2 L}{\partial \beta^2} &= \sum_{i=1}^2 \sum_{j=1}^m \frac{\partial}{\partial \beta} \phi_i (-1)^i [t_{ij} + d'(\phi_i)] \\
&= \sum_{i=1}^2 \sum_{j=1}^m (-1)^i \left[(-1)^i \phi_i [t_{ij} + d'(\phi_i)] \right] + \phi_i d''(\phi_i) \phi_i (-1)^i \\
&= \sum_{i=1}^2 \sum_{j=1}^m (-1)^{2i} \left[\phi_i^2 d''(\phi_i) + \phi_i [t_{ij} + d'(\phi_i)] \right] \\
&= \sum_{i=1}^2 \sum_{j=1}^m \left[\phi_i^2 d''(\phi_i) + \phi_i [t_{ij} + d'(\phi_i)] \right] \tag{2}
\end{aligned}$$

Para se chegar ao componente da informação de Fisher de β , $K_{\beta\beta}$, calculamos o valor esperado do negativo de (2):

$$\begin{aligned}
K_{\beta\beta} &= E \left(-\frac{\partial^2 L}{\partial \beta^2} \right) \\
&= - \sum_{i=1}^2 \sum_{j=1}^m \phi_i^2 d''(\phi_i)
\end{aligned}$$

Em seguida, vamos desenvolver os somatórios de $K_{\beta\beta}$:

$$\begin{aligned}
K_{\beta\beta} &= - \sum_{i=1}^2 \sum_{j=1}^m \phi_i^2 d''(\phi_i) \\
&= - \sum_{i=1}^2 m \phi_i^2 d''(\phi_i) \\
&= - \left[m \phi_1^2 d''(\phi_1) + m \phi_2^2 d''(\phi_2) \right] \\
&= -m \left[\phi_1^2 d''(\phi_1) + \phi_2^2 d''(\phi_2) \right] \tag{3}
\end{aligned}$$

Para chegar ao fato de que $\text{Var}(\hat{\beta}) = K_{\beta\beta}^{-1}$ sem precisar calcular a matriz de informação de Fisher por completo, basta notar que a matriz modelo Z que modela $\log(\phi_i)$ é:

$$Z = \begin{bmatrix} 1 & -1 \\ \vdots & \vdots \\ 1 & -1 \\ 1 & 1 \\ \vdots & \vdots \\ 1 & 1 \end{bmatrix}$$

E além disso $Z^T Z = 2m \cdot I$, ou seja uma matriz diagonal. Nesses casos a matriz de informação de Fisher também é diagonal. Assim para se obter variância assintótica do parâmetro de interesse basta obter o inverso do seu componente correspondente na matriz de Fisher, sem precisar calcular a matriz inteira e invertê-la em seguida. Nesse sentido, temos o seguinte resultado, partindo de (3)

$$\begin{aligned} \text{Var}(\hat{\beta}) &= \left[-\sum_{i=1}^2 \sum_{j=1}^m \phi_i^2 d''(\phi_i) \right]^{-1} \\ &= \left[-m \left(\phi_1^2 d''(\phi_1) + \phi_2^2 d''(\phi_2) \right) \right]^{-1} \end{aligned}$$

5.3 Estatística de escore

Primeiro vamos desenvolver os somatórios da função escore da mesma maneira que fizemos em (3):

$$\begin{aligned} U_\beta &= \sum_{i=1}^2 \sum_{j=1}^m \phi_i (-1)^i [t_{ij} + d'(\phi_i)] \\ &= \sum_{j=1}^m \phi_1 (-1) t_{1j} - \phi_1 d'(\phi_1) + \sum_{j=1}^m \phi_2 t_{2j} + \phi_2 d'(\phi_2) \\ &= \sum_{j=1}^m \phi_2 t_{2j} + \phi_2 d'(\phi_2) - \sum_{j=1}^m \phi_1 t_{1j} + \phi_1 d'(\phi_1) \\ &= \phi_2 \sum_{j=1}^m [t_{2j}] + m\phi_2 d'(\phi_2) - \phi_1 \sum_{j=1}^m [t_{1j}] - m\phi_1 d'(\phi_1) \\ &= \phi_2 m \bar{t}_2 + m\phi_2 d'(\phi_2) - \phi_1 m \bar{t}_1 - m\phi_1 d'(\phi_1) \end{aligned}$$

Sob $H_0 : \beta = 0$, temos que as estimativas $\phi_1 = \phi_2 = \phi_0$. Portanto, a função escore U_β é escrita da seguinte forma

$$\begin{aligned} U_\beta &= \phi_2 m \bar{t}_2 + m\phi_2 d'(\phi_2) - \phi_1 m \bar{t}_1 - m\phi_1 d'(\phi_1) \\ &\stackrel{H_0}{=} \phi_0 m \bar{t}_2 + m\phi_0 d'(\phi_0) - \phi_0 m \bar{t}_1 - m\phi_0 d'(\phi_0) \\ &\stackrel{H_0}{=} \phi_0 m \bar{t}_2 - \phi_0 m \bar{t}_1 \\ &\stackrel{H_0}{=} \phi_0 m (\bar{t}_2 - \bar{t}_1) \end{aligned}$$

E a variância assintótica, também sob a hipótese nula

$$\text{Var}(\hat{\beta}) = \left[-m \left(\phi_1^2 d''(\phi_1) + \phi_2^2 d''(\phi_2) \right) \right]^{-1}$$

$$\begin{aligned} &\stackrel{H_0}{=} \left[-m \left(\phi_0^2 d''(\phi_0) + \phi_0^2 d''(\phi_0) \right) \right]^{-1} \\ &\stackrel{H_0}{=} \left[-m \phi_0^2 (2d''(\phi_0)) \right]^{-1} \end{aligned}$$

Assim, munido dos fatos $U_\beta(\beta^0) = \phi_0 m (\bar{t}_2 - \bar{t}_1)$ e $\text{Var}_0(\hat{\beta}) = [-m \phi_0^2 (2d''(\phi_0))]^{-1}$, podemos montar a estatística de escore ξ_{SR} :

$$\begin{aligned} \xi_{SR} &= \left[\hat{U}_\beta(\beta^0) \right]^2 \cdot \left[\text{Var}_0(\hat{\beta}) \right] \\ &= \frac{\left[\hat{\phi}_0 m (\hat{t}_2 - \hat{t}_1) \right]^2}{-m \hat{\phi}_0^2 (2d''(\hat{\phi}_0))} \\ &= -\frac{\hat{\phi}_0^2 m^2 (\hat{t}_2 - \hat{t}_1)^2}{m \hat{\phi}_0^2 (2d''(\hat{\phi}_0))} \\ &= -\frac{m (\hat{t}_2 - \hat{t}_1)^2}{2d''(\hat{\phi}_0)} \end{aligned}$$

Onde $\hat{t}_i = \frac{1}{m} \sum_{j=1}^m \hat{t}_{ij}$ e $\hat{t}_{ij} = y_{ij} \hat{\theta} - b(\hat{\theta}) + u(y_{ij})$ e $\hat{\theta}$ foi estimado anteriormente e tratado como fixo nos cálculos que culminam na variável \hat{t}_{ij} .

Como T_{ij} é membro da família exponencial, os mesmos resultados assintóticos se aplicam. Nesses moldes $\xi_{SR} \rightarrow \chi_{(1)}^2$, pois apenas um parâmetro é testado.

5.4 Caso normal

Particularizando para o caso normal, os componentes presentes da estatística de escore são:

$$\hat{t}_{ij} = y_{ij} \hat{\mu} - \frac{1}{2} (\hat{\mu}^2 + y_{ij}^2)$$

$$d''(\hat{\phi}_0) = (-2\hat{\phi}_0^2)^{-1}$$

Partindo de (5.4), podemos ver que os componentes de média \hat{t}_i estão diretamente relacionados com a função desvio

$$\begin{aligned} \hat{t}_i &= \frac{1}{m} \sum_{j=1}^m y_{ij} \hat{\mu} - \frac{1}{2} (\hat{\mu}^2 + y_{ij}^2) \\ &= \frac{1}{m} \sum_{j=1}^m \frac{2}{2} y_{ij} \hat{\mu} - \frac{\hat{\mu}^2}{2} - \frac{y_{ij}^2}{2} \\ &= \frac{1}{m} \sum_{j=1}^m \frac{2y_{ij} \hat{\mu} - \mu^2 - y_{ij}^2}{2} \\ &= -\frac{1}{m} \sum_{j=1}^m \frac{\mu^2 + y_{ij}^2 - 2y_{ij} \hat{\mu}}{2} \end{aligned}$$

$$\begin{aligned}
&= -\frac{1}{2m} \sum_{j=1}^m \mu^2 + y_{ij}^2 - 2y_{ij}\hat{\mu} \\
&= -\frac{1}{2m} \sum_{j=1}^m (y_{ij} - \hat{\mu})^2 \\
&= -\frac{1}{2m} D(\mathbf{y}_i, \hat{\mu})
\end{aligned}$$

Assim, ξ_{SR} pode ser escrita como uma diferena de desvios entre os grupo $i = 1, 2$:

$$\begin{aligned}
\xi_{SR} &= -\frac{m \left(\hat{t}_2 - \hat{t}_1 \right)^2}{2d''(\hat{\phi}_0)} \\
&= -\frac{m \left(\frac{1}{2m} D(\mathbf{y}_1, \hat{\mu}) - \frac{1}{2m} D(\mathbf{y}_2, \hat{\mu}) \right)}{\left(-4\hat{\phi}_0^2 \right)^{-1}} \\
&= \frac{1}{2} (D(\mathbf{y}_1, \hat{\mu}) - D(\mathbf{y}_2, \hat{\mu})) 4\hat{\phi}_0^2 \\
&= 2\hat{\phi}_0^2 (D(\mathbf{y}_1, \hat{\mu}) - D(\mathbf{y}_2, \hat{\mu}))
\end{aligned}$$

Uma outra forma para poss vel ξ_{SR}   notando que $\frac{1}{m} D(\mathbf{y}_i, \hat{\mu}) = \left(\hat{\phi}_i \right)^{-1}$ e portanto:

$$\begin{aligned}
\xi_{SR} &= -\frac{m \left(\hat{t}_2 - \hat{t}_1 \right)^2}{2d''(\hat{\phi}_0)} \\
&= -\frac{m}{2} \left(\frac{1}{2\hat{\phi}_1} - \frac{1}{2\hat{\phi}_2} \right) \cdot \left(-2\hat{\phi}_0^2 \right) \\
&= \frac{\hat{\phi}_0^2 m}{2} \left(\frac{1}{\hat{\phi}_1} - \frac{1}{\hat{\phi}_2} \right)
\end{aligned}$$