

MAE5763 - Modelos Lineares Generalizados - Resolução da Prova 1

Guilherme Marthe - 8661962

6/11/2020

1 Exercício 1

1.1 Matriz X e W

O modelo descrito no enunciado consiste tem $Y_{ij} \stackrel{ind}{\sim} FE(\mu_i, \phi)$ com $i = 1, 2, 3$ e $j = 1, \dots, m$. A parte sistemática é descrita como:

$$g(\mu_1) = \alpha$$

$$g(\mu_2) = \alpha - \Delta$$

$$g(\mu_3) = \alpha + \Delta$$

Desta forma, a matriz modelo de cada bloco $i = 1, 2, 3$ é dada por

$$X_1 = \begin{bmatrix} 1 & 0 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \end{bmatrix}_{m \times 2} \quad X_2 = \begin{bmatrix} 1 & -1 \\ 1 & -1 \\ \vdots & \vdots \\ 1 & -1 \end{bmatrix}_{m \times 2} \quad X_3 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ \vdots & \vdots \\ 1 & 1 \end{bmatrix}_{m \times 2}$$

E a matriz modelo é composta pelo subcomponentes X_i de tal forma que:

$$X = \begin{bmatrix} X_1 \\ X_2 \\ X_2 \end{bmatrix}_{3m \times 2}$$

A matriz de pesos W é composta, como de usual, por uma matriz diagonal onde elementos na diagonal principal são $w_i = \left(\frac{d\mu_i}{d\eta_i}\right)^2 V_i^{-1}$ com $\eta_i = g(\mu_i)$ e zero em todo resto. Os elementos w_i se repetem m vezes para cada $i = 1, 2, 3$ resultando numa matriz quadrada $3m \times 3m$. Ou seja:

$$W = \text{diag}\{w_1, \dots, w_1, w_2, \dots, w_2, w_3, \dots, w_3\}_{3m \times 3m}$$

1.2 Variância assintótica

Para se obter a variância assintótica do estimador $\hat{\Delta}$ iremos utilizar o seguinte resultado de MLGs. Sendo $\theta = (\alpha, \Delta)^T$, temos que a matriz de informação de Fisher pode ser escrita em forma matricial como:

$$K_{\theta\theta} = \phi X^T W X$$

E a variância assintótica $Var(\hat{\Delta}) = K_{\Delta\Delta}^{-1}$. Seguimos com a computação de $K_{\theta\theta}$:

$$\begin{aligned} X^T W &= \begin{bmatrix} 1 & \dots & 1 & 1 & \dots & 1 & 1 & \dots & 1 \\ 0 & \dots & 0 & -1 & \dots & -1 & 1 & \dots & 1 \end{bmatrix}_{2 \times 3m} \cdot \text{diag}\{w_1, \dots, w_1, w_2, \dots, w_2, w_3, \dots, w_3\}_{3m \times 3m} \\ &= \begin{bmatrix} w_1 & \dots & w_1 & w_2 & \dots & w_2 & w_3 & \dots & w_3 \\ 0 & \dots & 0 & -w_2 & \dots & -w_2 & w_3 & \dots & w_3 \end{bmatrix}_{2 \times 3m} \end{aligned}$$

$$\begin{aligned} X^T W X &= \begin{bmatrix} w_1 & \dots & w_1 & w_2 & \dots & w_2 & w_3 & \dots & w_3 \\ 0 & \dots & 0 & -w_2 & \dots & -w_2 & w_3 & \dots & w_3 \end{bmatrix}_{2 \times 3m} \cdot \begin{bmatrix} 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 1 & -1 \\ \vdots & \vdots \\ 1 & -1 \\ 1 & 1 \\ \vdots & \vdots \\ 1 & 1 \end{bmatrix}_{3m \times 2} \\ &= \begin{bmatrix} mw_1 + mw_2 + mw_3 & mw_3 - mw_2 \\ mw_3 - mw_2 & mw_2 + mw_3 \end{bmatrix} \\ &= m \begin{bmatrix} \sum_{i=1}^3 w_i & w_3 - w_2 \\ w_3 - w_2 & w_3 + w_2 \end{bmatrix} \end{aligned}$$

Assim, a matriz de informação de Fisher fica com a seguinte forma:

$$K_{\theta\theta} = \phi m \begin{bmatrix} \sum_{i=1}^3 w_i & w_3 - w_2 \\ w_3 - w_2 & w_3 + w_2 \end{bmatrix}$$

O determinante da matriz, nomeadamente J , na expressão anterior será necessário para os próximos cálculos:

$$\det(J) = \left[\sum_{i=1}^3 w_i \right] (w_3 + w_2) - (w_3 - w_2)^2$$

Assim temos o seguinte resultado:

$$K_{\theta\theta}^{-1} = \frac{1}{\phi m \left[\sum_{i=1}^3 w_i \right] (w_3 + w_2) - (w_3 - w_2)^2} \begin{bmatrix} w_3 + w_2 & w_2 - w_3 \\ w_2 - w_3 & \sum_{i=1}^3 w_i \end{bmatrix}$$

Assim a variância assintótica de $\hat{\Delta}$ é o elemento de interesse em $K_{\theta\theta}^{-1}$, ou seja:

$$Var(\hat{\Delta}) = K_{\Delta\Delta}^{-1} = \frac{\sum_{i=1}^3 w_i}{\phi m \left[\sum_{i=1}^3 w_i \right] (w_3 + w_2) - (w_3 - w_2)^2}$$

1.3 Função Escore U_{Δ}

Para o caso dos MLGs o vetor de funções escore dos parâmetros é:

$$U_{\theta} = \phi X^T W^{1/2} V^{-1/2} (y - \mu)$$

Onde X é a matriz modelo, W é a matriz de pesos, apresentadas anteriormente. V é a matriz de funções variância. Porém, para a estatística de escore requisitada, só é necessário computar a função escore do parâmetro testado. Ou seja:

$$U_{\Delta} = \phi X_{\Delta}^T W^{1/2} V^{-1/2} (y - \mu)$$

Onde

$$X_{\Delta} = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ -1 \\ \vdots \\ -1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}_{3m \times 1}$$

Iremos a seguir calcular cada um dos fatores para se chegar em U_{Δ} .

$$\begin{aligned} X_{\Delta}^T W^{1/2} &= \begin{bmatrix} 0 & \dots & 0 & -1 & \dots & -1 & 1 & \dots & 1 \end{bmatrix}_{1 \times 3m} \cdot \text{diag}\{\sqrt{w_1}, \dots, \sqrt{w_1}, \sqrt{w_2}, \dots, \sqrt{w_2}, \sqrt{w_3}, \dots, \sqrt{w_3}\}_{3m \times 3m} \\ &= \begin{bmatrix} 0 & \dots & 0 & -\sqrt{w_2} & \dots & -\sqrt{w_2} & \sqrt{w_3} & \dots & \sqrt{w_3} \end{bmatrix} \end{aligned}$$

$$X_{\Delta}^T W^{1/2} V^{-1/2} = \begin{bmatrix} 0 & \dots & 0 & \frac{-\sqrt{w_2}}{\sqrt{V_2}} & \dots & \frac{-\sqrt{w_2}}{\sqrt{V_2}} & \frac{\sqrt{w_3}}{\sqrt{V_3}} & \dots & \frac{\sqrt{w_3}}{\sqrt{V_3}} \end{bmatrix}$$

Por fim, temos

$$U_{\Delta} = \phi X_{\Delta}^T W^{1/2} V^{-1/2} (y - \mu)$$

$$\begin{aligned}
&= \phi \begin{bmatrix} 0 & \dots & 0 & \frac{-\sqrt{w_2}}{\sqrt{V_2}} & \dots & \frac{-\sqrt{w_2}}{\sqrt{V_2}} & \frac{\sqrt{w_3}}{\sqrt{V_3}} & \dots & \frac{\sqrt{w_3}}{\sqrt{V_3}} \end{bmatrix} \begin{bmatrix} y_{11} - \mu_1 \\ \vdots \\ y_{1m} - \mu_1 \\ y_{21} - \mu_2 \\ \vdots \\ y_{2m} - \mu_2 \\ y_{31} - \mu_3 \\ \vdots \\ y_{3m} - \mu_3 \end{bmatrix} \\
&= \phi \left[-\frac{\sqrt{w_2}}{\sqrt{V_2}} \sum_{j=1}^m (y_{2j} - \mu_2) + \frac{\sqrt{w_3}}{\sqrt{V_3}} \sum_{j=1}^m (y_{3j} - \mu_3) \right] \\
&= \phi \left[-\frac{\sqrt{w_2}}{\sqrt{V_2}} m(\bar{y}_2 - \mu_2) + \frac{\sqrt{w_3}}{\sqrt{V_3}} m(\bar{y}_3 - \mu_3) \right] \\
&= \phi m \left[\frac{\sqrt{w_3}}{\sqrt{V_3}} (\bar{y}_3 - \mu_3) - \frac{\sqrt{w_2}}{\sqrt{V_2}} (\bar{y}_2 - \mu_2) \right]
\end{aligned}$$

1.4 Estatística de escore

Com a função escore e a variância assintótica calculadas anteriormente, o próximo passo para calcular a estatística de escore consiste em identificar essas funções sob as suposições da hipótese nula. No nosso caso queremos testar $H_0 : \Delta = 0$ contra $H_1 : \Delta \neq 0$. Note que, sob H_0 :

$$\begin{aligned}
w_i &\xrightarrow{H_0} w \\
V_i &\xrightarrow{H_0} V \\
\mu_i &= g^{-1}(\eta_i) \xrightarrow{H_0} \mu = g^{-1}(\alpha_0) = \bar{y}
\end{aligned}$$

Os componentes da estatística de escore sob H_0 são:

$$\begin{aligned}
Var(\hat{\Delta}) &= \frac{\sum_{i=1}^3 w_i}{\phi m \left[\sum_{i=1}^3 w_i \right] (w_3 + w_2) - (w_3 - w_2)^2} \\
&\downarrow
\end{aligned}$$

$$Var_0(\hat{\Delta}) = \frac{3w}{\phi m 3w 2w - 0} = \frac{1}{2\phi m w}$$

$$\begin{aligned}
U_{\Delta} &= \phi m \left[\frac{\sqrt{w_3}}{\sqrt{V_3}} (\bar{y}_3 - \mu_3) - \frac{\sqrt{w_2}}{\sqrt{V_2}} (\bar{y}_2 - \mu_2) \right] \\
&\downarrow
\end{aligned}$$

$$U_{\Delta}^0 = \phi m \left[\frac{\sqrt{w}}{\sqrt{V}} (\bar{y}_3 - \bar{y}) - \frac{\sqrt{w}}{\sqrt{V}} (\bar{y}_2 - \bar{y}) \right]$$

$$= \frac{\phi m \sqrt{w}}{\sqrt{V}} (\bar{y}_3 - \bar{y}_2)$$

Assim a estatística de escore fica com a seguinte forma:

$$\begin{aligned} \xi_{SR} &= \left[U_{\Delta}^0 \right]^2 \cdot \left[\text{Var}_0(\hat{\Delta}) \right] \\ &= \frac{\phi^2 m^2 w}{V} (\bar{y}_3 - \bar{y}_2)^2 \frac{1}{2\phi m w} \\ &= \frac{\phi m}{2V} (\bar{y}_3 - \bar{y}_2)^2 \end{aligned}$$

Como apenas um parâmetro é testado, nomeadamente Δ , $\xi_{SR} \rightarrow \chi_{(1)}^2$ quando n cresce e prevalece a hipótese nula.

2 Exercício 2

O enunciado apresenta $Z_i \stackrel{ind}{\sim} \text{ZAP}(\mu_i, \pi_i)$, ou seja, uma poisson ajustada em zeros, com a seguinte função de probabilidades:

$$f_Z(z_i; \mu_i, \pi_i) = \begin{cases} \pi_i & \text{se } z_i = 0 \\ (1 - \pi_i) \frac{f_Y(z_i; \mu_i)}{1 - f_Y(0; \mu_i)} & \text{se } z_i > 0 \end{cases}$$

Onde $f_Y(z_i, \mu_i) = \frac{e^{-\mu_i} \mu_i^{z_i}}{z_i!}$, $z_i = 1, 2, 3, \dots$ e $i = 1, \dots, n$. Pedese então para encontrar a função desvio para uma estimativa dessa distribuição, assumindo que o modelo saturado é o mesmo de uma variável aleatória Poisson usual. A definição da função desvio parte de uma diferença de log-verossimilhanças do modelo saturado e do modelo ajustado:

$$D^*(z, \hat{\mu}, \hat{\pi}) = 2\{L(z, \tilde{\mu}, \tilde{\pi}) - L(z, \hat{\mu}, \hat{\pi})\}$$

Quando escrita em função dos parâmetros genéricos, sem indicação de se é sob o modelo saturado ou estimado, o log da função de verossimilhanças é escrito como uma soma, onde defino um componente da soma como l_i , ou seja

$$L(z, \mu, \pi) = \sum_{i=1}^n \log(f_Z(z_i, \mu_i, \pi_i)) = \sum_{i=1}^n l_i$$

No caso da distribuição poisson ajustada em zero, o componente l_i é escrito de duas maneiras distintas. Se $z_i > 0$

$$l_i = \log(1 - \pi_i) - \mu_i + z_i \log \mu_i - \log z_i! - \log(1 - e^{-\mu_i})$$

E se $z_i = 0$

$$l_i = \log(\pi_i)$$

2.1 Modelo saturado

Conforme fornecido pelo enunciado, o modelo saturado para o nosso caso é talque $\tilde{\mu}_i = z_i$. Porém precisamos pensar um pouco sobre o parâmetro π_i . Como foi definido o modelo, podemos pensar na ocorrência de zeros como uma variável Bernoulli onde o sucesso corresponde em $z_i = 0$. Heuristicamente, podemos definir a situação em que a maximização da verossimilhança seria “ideal”, ou “teto da igreja”, para esta porção da distribuição ZAP desta forma. Então, o parâmetro saturado para π_i é definido por nós como:

$$\tilde{\pi}_i = \begin{cases} 0 & \text{se } z_i > 0 \\ 1 & \text{se } z_i = 0 \end{cases}$$

2.2 Componente do desvio

Com a definição do modelo saturado podemos partir para o cálculo dos componente do desvio. Para o caso em que $z_i > 0$:

$$d^*(z_i, \hat{\mu}_i, \hat{\pi}_i) = 2 \left(\tilde{l}_i - \hat{l}_i \right)$$

Expandindo essa diferença temos:

$$2 \left(\log(1 - \tilde{\pi}_i) - \tilde{\mu}_i + z_i \log \tilde{\mu}_i - \log z_i! - \log(1 - e^{-\tilde{\mu}_i}) - \log(1 - \hat{\pi}_i) + \hat{\mu}_i - z_i \log \hat{\mu}_i + \log z_i! + \log(1 - e^{-\hat{\mu}_i}) \right)$$

E substituindo os parâmetros saturados:

$$2 \left(\log(1 - 0) - z_i + z_i \log z_i - \log z_i! - \log(1 - e^{-z_i}) - \log(1 - \hat{\pi}_i) + \hat{\mu}_i - z_i \log \hat{\mu}_i + \log z_i! + \log(1 - e^{-\hat{\mu}_i}) \right)$$

Resultando em:

$$d^*(z_i, \hat{\mu}_i, \hat{\pi}_i) = 2 \left[\log \left(\frac{1}{1 - \hat{\pi}_i} \right) + (\hat{\mu}_i - z_i) + z_i \log \left(\frac{z_i}{\hat{\mu}_i} \right) + \log \left(\frac{1 - e^{-z_i}}{1 - e^{-\hat{\mu}_i}} \right) \right]$$

O próximo caso de interesse é se $z_i = 0$. Partindo da mesma definição, porém com uma computação mais direta, temos:

$$\begin{aligned} d^*(z_i, \hat{\mu}_i, \hat{\pi}_i) &= 2 \left(\tilde{l}_i - \hat{l}_i \right) \\ &= 2(\log(\tilde{\pi}_i) - \log(\hat{\pi}_i)) \\ &= 2(\log(1) - \log(\hat{\pi}_i)) \\ &= -2\log(\hat{\pi}_i) \end{aligned}$$

Em conclusão, o componente do desvio para a variável é:

$$d^*(z_i, \hat{\mu}_i, \hat{\pi}_i) = \begin{cases} -2\log(\hat{\pi}_i) & \text{se } z_i = 0 \\ 2 \left[\log \left(\frac{1}{1 - \hat{\pi}_i} \right) + (\hat{\mu}_i - z_i) + z_i \log \left(\frac{z_i}{\hat{\mu}_i} \right) + \log \left(\frac{1 - e^{-z_i}}{1 - e^{-\hat{\mu}_i}} \right) \right] & \text{se } z_i > 0 \end{cases}$$

3 Exercício 3

Uma variável aleatória modelada por uma distribuição logarítmica $Y_i \stackrel{iid}{\sim} LG(\rho)$ tem a seguinte função de probabilidades:

$$f(y_i; \rho) = \frac{\rho^{y_i}}{-y_i \log(1 - \rho)}$$

Com $y_i = 1, 2, \dots, i = 1, \dots, n$ e $0 < \rho < 1$

Vamos iniciar a resolução do problema mostrando que Y_i pertencem à família exponencial, pois os resultados nos ajudarão a montar a estatística de razão de verossimilhanças.

3.1 Família exponencial

A forma da função de probabilidades pertencente à família exponencial é a seguinte:

$$f_Y(y; \theta, \phi) = \exp\{\phi[y\theta - b(\theta)] + c(y; \phi)\}$$

Se manipularmos a função de probabilidades de Y_i de tal forma que (omitindo o subscrito i)

$$f(y; \rho) = \frac{\rho^y}{-y \log(1 - \rho)} = \exp[y \log \rho - \log(-\log(1 - \rho)) - \log y]$$

Podemos definir $\phi = 1$, $c(y; \phi) = -\log y$, o parâmetro canônico $\theta = \log \rho$ e

$$b(\theta) = \log(-\log(1 - \rho)) = \log(-\log(1 - e^\theta))$$

O valor esperado de Y_i pode ser obtido derivando $b(\theta)$

$$\begin{aligned} E(Y) &= \mu \\ &= b'(\theta) \\ &= \frac{d}{d\theta} \log(-\log(1 - e^\theta)) \\ &= \frac{1}{-\log(1 - e^\theta)} (-1) \frac{1}{1 - e^\theta} (-1) e^\theta \\ &= \frac{-1}{\log(1 - e^\theta)} \frac{e^\theta}{1 - e^\theta} \\ &= \frac{-1}{\log(1 - \rho)} \frac{\rho}{1 - \rho} \end{aligned}$$

No enunciado, é sugerida a seguinte parametrização

$$\rho = \frac{e^\alpha}{1 + e^\alpha}$$

Assim, o valor esperado μ em termos dessa parametrização é

$$\mu = \frac{-1}{\log(1 - \rho)} \frac{\rho}{1 - \rho}$$

$$\begin{aligned}
&= \frac{ae^\alpha(1+e^\alpha)^{-1}}{\log\left(1 - \frac{e^\alpha}{1+e^\alpha}\right)\left(1 - \frac{e^\alpha}{1+e^\alpha}\right)} \\
&= \frac{-e^\alpha(1+e^\alpha)^{-1}}{-\log(1+e^\alpha)(1+e^\alpha)^{-1}} \\
&= \frac{e^\alpha}{\log(1+e^\alpha)}
\end{aligned}$$

3.2 Variância assintótica

O cálculo da variância assintótica de $\hat{\alpha}$ passa pela determinação do log da função de verossimilhança, em seguida pela função escore e por fim da informação de Fisher associada à esse parâmetro. Iniciaremos pela verossimilhança:

$$LL(y; \rho) = \sum_{i=1}^n y_i \log \rho - \log(-y_i \log(1 - \rho))$$

Porém, é necessário deixar a verossimilhança em função de α . Para tanto, é necessário mostrar algumas identidades da parametrização:

$$\begin{aligned}
\rho &= \frac{e^\alpha}{1+e^\alpha} \leftrightarrow \\
\log \rho &= \log(e^\alpha) - \log(1+e^\alpha) \leftrightarrow \\
\log \rho &= \alpha - \log(1+e^\alpha)
\end{aligned}$$

E

$$\begin{aligned}
\rho &= \frac{e^\alpha}{1+e^\alpha} \leftrightarrow \\
-\rho &= -\frac{e^\alpha}{1+e^\alpha} \leftrightarrow \\
1 - \rho &= 1 - \frac{e^\alpha}{1+e^\alpha} = \frac{1}{1+e^\alpha} \leftrightarrow \\
\log(1 - \rho) &= \log(1) - \log(1+e^\alpha) \leftrightarrow \\
\log(1 - \rho) &= -\log(1+e^\alpha)
\end{aligned}$$

Assim, a expressão de $LL(y_i; \rho)$ pode ser escrita em função de α tal que:

$$\begin{aligned}
LL(y_i; \alpha) &= \sum_{i=1}^n y_i (\alpha - \log(1+e^\alpha)) - \log(-y_i(-\log(1+e^\alpha))) \\
&= \sum_{i=1}^n y_i \alpha - y_i \log(1+e^\alpha) - \log(y_i \log(1+e^\alpha)) \\
&= \sum_{i=1}^n y_i \alpha - y_i \log(1+e^\alpha) - \log(y_i) - \log(\log(1+e^\alpha))
\end{aligned}$$

Assim, a função escore é obtida ao derivar a expressão anterior:

$$\begin{aligned}
U_\alpha &= \frac{dLL}{d\alpha} \\
&= \sum_{i=1}^n \left[y_i - \frac{y_i e^\alpha}{1 + e^\alpha} - \frac{e^\alpha}{\log(1 + e^\alpha)(1 + e^\alpha)} \right] \\
&= \sum_{i=1}^n y_i - \frac{e^\alpha}{1 + e^\alpha} \sum_{i=1}^n y_i - \frac{ne^\alpha}{\log(1 + e^\alpha)(1 + e^\alpha)} \\
&= \left[1 - \frac{e^\alpha}{1 + e^\alpha} \right] \sum_{i=1}^n y_i - \frac{ne^\alpha}{\log(1 + e^\alpha)(1 + e^\alpha)} \\
&= \frac{1}{1 + e^\alpha} \sum_{i=1}^n y_i - \frac{ne^\alpha}{\log(1 + e^\alpha)(1 + e^\alpha)} \\
&= \frac{n}{1 + e^\alpha} \left[\bar{y} - \frac{e^\alpha}{\log(1 + e^\alpha)} \right]
\end{aligned}$$

Em seguida, partimos para o cálculo da segunda derivada de $LL(y_i; \alpha)$:

$$\frac{d^2 LL}{d\alpha^2} = \frac{d}{d\alpha} \left\{ \frac{n}{1 + e^\alpha} \left[\bar{y} - \frac{e^\alpha}{\log(1 + e^\alpha)} \right] \right\}$$

Onde, ao aplicarmos a regra da derivada do produto de funções, resulta em:

$$\frac{d^2 LL}{d\alpha^2} = -\frac{n}{(1 + e^\alpha)^2} \left[\bar{y} - \frac{e^\alpha}{\log(1 + e^\alpha)} \right] + \frac{n}{1 + e^\alpha} \frac{e^\alpha \log(1 + e^\alpha) - e^\alpha (1 + e^\alpha)^{-1} e^\alpha}{\log(1 + e^\alpha)^2}$$

Com o negativo do valor esperado dessa expressão chegaremos na informação de Fisher para α .

$$\begin{aligned}
K_{\alpha\alpha} &= E \left(-\frac{d^2 LL}{d\alpha^2} \right) \\
&= -\frac{n}{(1 + e^\alpha)^2} \left[\mu - \frac{e^\alpha}{\log(1 + e^\alpha)} \right] + \frac{n}{1 + e^\alpha} \left[\frac{e^\alpha \log(1 + e^\alpha) - e^\alpha (1 + e^\alpha)^{-1} e^\alpha}{\log(1 + e^\alpha)^2} \right]
\end{aligned}$$

Porém, note que μ em termos do parâmetro α foi calculado na etapa de prova da família exponencial. E sua expressão é:

$$\mu = \frac{e^\alpha}{\log(1 + e^\alpha)}$$

Por consequência a primeira parcela de $K_{\alpha\alpha}$ é anulada, sendo

$$K_{\alpha\alpha} = \frac{n}{1 + e^\alpha} \left[\frac{e^\alpha \log(1 + e^\alpha) - e^\alpha (1 + e^\alpha)^{-1} e^\alpha}{\log(1 + e^\alpha)^2} \right]$$

No enunciado nos é fornecido a função $\tau(\alpha) = (1 + e^\alpha) \log(1 + e^\alpha)$. Manipulando expressão anterior, podemos evidenciar essa função e simplificar ainda mais a informação de Fisher:

$$\begin{aligned}
K_{\alpha\alpha} &= \frac{n}{1+e^\alpha} \left[\frac{e^\alpha \log(1+e^\alpha) - e^\alpha(1+e^\alpha)^{-1}e^\alpha}{\log(1+e^\alpha)^2} \right] \\
&= \frac{ne^\alpha}{1+e^\alpha} \left[\frac{\log(1+e^\alpha) - (1+e^\alpha)^{-1}e^\alpha}{\log(1+e^\alpha)^2} \right] \\
&= \frac{ne^\alpha}{(1+e^\alpha) \log(1+e^\alpha)^2} \left[\log(1+e^\alpha) - (1+e^\alpha)^{-1}e^\alpha \right] \\
&= \frac{ne^\alpha(1+e^\alpha)}{(1+e^\alpha)^2 \log(1+e^\alpha)^2} \left[\log(1+e^\alpha) - (1+e^\alpha)^{-1}e^\alpha \right] \\
&= \frac{ne^\alpha}{(1+e^\alpha)^2 \log(1+e^\alpha)^2} \left[(1+e^\alpha) \log(1+e^\alpha) - (1+e^\alpha)(1+e^\alpha)^{-1}e^\alpha \right] \\
&= \frac{ne^\alpha}{(1+e^\alpha)^2 \log(1+e^\alpha)^2} \left[(1+e^\alpha) \log(1+e^\alpha) - e^\alpha \right] \\
&= \frac{ne^\alpha}{\tau(\alpha)^2} [\tau(\alpha) - e^\alpha]
\end{aligned}$$

Finalmente, variância assintótica de $\hat{\alpha}$ é obtida a partir da inversa da informação de Fisher $K_{\alpha\alpha}$, ou seja:

$$\text{Var}(\hat{\alpha}) = K_{\alpha\alpha}^{-1} = \frac{\tau(\alpha)^2}{ne^\alpha [\tau(\alpha) - e^\alpha]}$$

3.3 Teste de razão de verossimilhanças

Em seguida iremos buscar o teste de razão de verossimilhanças para testar $H_0 : \alpha = 0$ contra $H_1 : \alpha \neq 0$. O teste pode ser escrito para o nosso caso como:

$$\xi_{RV} = 2[LL(y_i; \hat{\alpha}) - LL(y_i; 0)]$$

Como já escrevemos anteriormente, o logaritmo da função verossimilhança para a distribuição logarítmica na parametrização que estamos estudando é

$$LL(y_i; \alpha) = \sum_{i=1}^n y_i \alpha - y_i \log(1+e^\alpha) - \log(y_i) - \log(\log(1+e^\alpha))$$

Assim, a estimativa sob H_0 é:

$$\begin{aligned}
LL(y_i; 0) &= \sum_{i=1}^n y_i 0 - y_i \log(1+1) - \log(y_i) - \log(\log(1+1)) \\
&= \sum_{i=1}^n -y_i \log(2) - \log(y_i) - \log(\log(2)) \\
&= -\log(2)n\bar{y} - n \log(\log(2)) - \sum_{i=1}^n \log(y_i)
\end{aligned}$$

E sob a estimativa

$$\begin{aligned}
LL(y_i; \hat{\alpha}) &= \sum_{i=1}^n y_i \hat{\alpha} - y_i \log(1 + e^{\hat{\alpha}}) - \log(y_i) - \log(\log(1 + e^{\hat{\alpha}})) \\
&= \hat{\alpha} \sum_{i=1}^n y_i - \log(1 + e^{\hat{\alpha}}) \sum_{i=1}^n y_i - n \log(\log(1 + e^{\hat{\alpha}})) - \sum_{i=1}^n \log(y_i) \\
&= \hat{\alpha} n \bar{y} - \log(1 + e^{\hat{\alpha}}) n \bar{y} - n \log(\log(1 + e^{\hat{\alpha}})) - \sum_{i=1}^n \log(y_i)
\end{aligned}$$

A estatística do teste de razão de verossimilhanças é:

$$\begin{aligned}
\xi_{RV} &= 2[LL(y_i; \hat{\alpha}) - LL(y_i; 0)] \\
&= \hat{\alpha} n \bar{y} - \log(1 + e^{\hat{\alpha}}) n \bar{y} - n \log(\log(1 + e^{\hat{\alpha}})) - \sum_{i=1}^n \log(y_i) - \left(-\log(2) n \bar{y} - n \log(\log(2)) - \sum_{i=1}^n \log(y_i) \right) \\
&= \hat{\alpha} n \bar{y} - \log(1 + e^{\hat{\alpha}}) n \bar{y} - n \log(\log(1 + e^{\hat{\alpha}})) - \sum_{i=1}^n \log(y_i) + \log(2) n \bar{y} + n \log(\log(2)) + \sum_{i=1}^n \log(y_i) \\
&= \hat{\alpha} n \bar{y} - \log(1 + e^{\hat{\alpha}}) n \bar{y} - n \log(\log(1 + e^{\hat{\alpha}})) + \log(2) n \bar{y} + n \log(\log(2)) \\
&= n \left(\hat{\alpha} \bar{y} - \log(1 + e^{\hat{\alpha}}) \bar{y} - \log(\log(1 + e^{\hat{\alpha}})) + \log(2) \bar{y} + \log(\log(2)) \right) \\
&= n \left[\bar{y} \left(\hat{\alpha} + \log(2) - \log(1 + e^{\hat{\alpha}}) \right) - \log(\log(1 + e^{\hat{\alpha}})) + \log(\log(2)) \right] \\
&= n \left[\bar{y} \left(\hat{\alpha} + \log(2) - \log(1 + e^{\hat{\alpha}}) \right) - \log(\log(1 + e^{\hat{\alpha}}) \log(2)) \right]
\end{aligned}$$

A estatística ξ_{RV} segue, assintoticamente e sob H_0 uma distribuição qui-quadrado com um grau de liberdade, uma vez que só um parâmetro, α , é testado.

4 Exercício 4

Seja $Y_i \stackrel{iid}{\sim} ZTP(\lambda)$, ou seja uma variável Poisson truncada em zeros. Sua função de probabilidades é

$$f(y_i; \lambda) = \frac{e^{-\lambda} \lambda^{y_i}}{y_i! (1 - e^{-\lambda})}$$

Onde $i = 1, \dots, n$ e $y_i = 1, 2, \dots$. Calcularemos primeiro o valor esperado de Y_i e em seguida sua variância.

4.1 Valor esperado

Para o cálculo do valor esperado, iremos omitir o subscrito i , para manter uma manipulação mais limpa.

$$\begin{aligned}
E(Y) &= \sum_{y=1}^{\infty} y f(y; \lambda) \\
&= \sum_{y=1}^{\infty} y \frac{e^{-\lambda} \lambda^y}{y! (1 - e^{-\lambda})} \\
&= \frac{e^{-\lambda}}{(1 - e^{-\lambda})} \sum_{y=1}^{\infty} \frac{\lambda^y}{(y-1)!}
\end{aligned}$$

$$= \frac{\lambda e^{-\lambda}}{(1 - e^{-\lambda})} \sum_{y=1}^{\infty} \frac{\lambda^{y-1}}{(y-1)!}$$

Fazendo a transformação de índices tal que $z = y - 1$ e notando que se $y = 1 \rightarrow z = 0$, temos uma expansão de taylor exponencial na série com relação à variável z . Com esse fato e um pouco mais de manipulação algébrica, chegamos na expressão buscada:

$$\begin{aligned} E(Y) &= \frac{\lambda e^{-\lambda}}{(1 - e^{-\lambda})} \sum_{y=1}^{\infty} \frac{\lambda^{y-1}}{(y-1)!} \\ &= \frac{\lambda e^{-\lambda}}{(1 - e^{-\lambda})} \sum_{z=0}^{\infty} \frac{\lambda^z}{(z)!} \\ &= \frac{\lambda e^{-\lambda}}{(1 - e^{-\lambda})} e^{\lambda} \\ &= \frac{\lambda}{(1 - e^{-\lambda})} \\ &= \frac{\lambda}{(1 - e^{-\lambda})} \frac{e^{\lambda}}{e^{\lambda}} \\ &= \frac{\lambda e^{\lambda}}{(e^{\lambda} - 1)} = \mu \end{aligned}$$

4.2 Variância

O cálculo variância será algebricamente similar ao do valor esperado. Porém utilizaremos adicionalmente a seguinte identidade:

$$E(Y) = E(Y^2) - [E(Y)]^2$$

Iniciaremos pelo cálculo do segundo momento de Y :

$$\begin{aligned} E(Y^2) &= \sum_{y=1}^{\infty} y^2 f(y; \lambda) \\ &= \sum_{y=1}^{\infty} y^2 \frac{e^{-\lambda} \lambda^y}{y!(1 - e^{-\lambda})} \\ &= \frac{e^{-\lambda}}{(1 - e^{-\lambda})} \sum_{y=1}^{\infty} \frac{y \lambda^y}{(y-1)!} \\ &= \frac{\lambda e^{-\lambda}}{(1 - e^{-\lambda})} \sum_{y=1}^{\infty} \frac{y \lambda^{y-1}}{(y-1)!} \\ &= \frac{\lambda e^{-\lambda}}{(1 - e^{-\lambda})} \sum_{z=0}^{\infty} \frac{(z+1) \lambda^z}{(z)!} \quad (\text{tomando } z = y - 1) \\ &= \frac{\lambda e^{-\lambda}}{(1 - e^{-\lambda})} \left[\sum_{z=0}^{\infty} \frac{\lambda^z}{(z)!} + \sum_{z=0}^{\infty} \frac{z \lambda^z}{(z)!} \right] \end{aligned}$$

$$\begin{aligned}
&= \frac{\lambda e^{-\lambda}}{(1 - e^{-\lambda})} \left[e^{\lambda} + \sum_{z=1}^{\infty} \frac{z \lambda^z}{(z)!} \right] \quad \text{o primeiro termo da soma é nulo} \\
&= \frac{\lambda e^{-\lambda}}{(1 - e^{-\lambda})} \left[e^{\lambda} + \lambda \sum_{z=1}^{\infty} \frac{\lambda^{z-1}}{(z-1)!} \right] \\
&= \frac{\lambda e^{-\lambda}}{(1 - e^{-\lambda})} [e^{\lambda} + \lambda e^{\lambda}]
\end{aligned}$$

Onde a última igualdade parte de um outra mudança de variável que culmina novamente numa expansão de Taylor exponencial ao redor de λ . Avançando com as manipulações para uma versão mais amigável do segundo momento, temos

$$\begin{aligned}
E(Y^2) &= \frac{\lambda}{(1 - e^{-\lambda})} [1 + \lambda] \\
&= \mu[1 + \lambda]
\end{aligned}$$

Por fim

$$\begin{aligned}
E(Y) &= E(Y^2) - [E(Y)]^2 \\
&= \mu[1 + \lambda] + \mu^2 \\
&= \mu[1 + \lambda - \mu]
\end{aligned}$$

Que é a expressão no enunciado.

4.3 Função escore

Para o cálculo da informação de Fisher do parâmetro λ e da estatística de escore, é necessário partir do função escore do parâmetro.

O logaritmo da verossimilhança para a amostra $i = 1, \dots, n$ de $Y_i \stackrel{iid}{\sim} ZTP(\mu)$ é:

$$\begin{aligned}
LL(y_i; \lambda) &= \sum_{i=1}^n \log \frac{e^{-\lambda} \lambda^{y_i}}{y_i! (1 - e^{-\lambda})} \\
&= \sum_{i=1}^n \log e^{-\lambda} + \log \lambda^{y_i} - \log y_i! - \log(1 - e^{-\lambda}) \\
&= \sum_{i=1}^n -\lambda + y_i \log \lambda - \log y_i! - \log(1 - e^{-\lambda}) \\
&= -n\lambda + \log \lambda \sum_{i=1}^n y_i - \sum_{i=1}^n \log y_i! - n \log(1 - e^{-\lambda})
\end{aligned}$$

A função escore é obtida ao derivar o logaritmo da verossimilhança para com relação ao parâmetro de interesse (que no caso é apenas o λ):

$$U_{\lambda} = \frac{dLL}{d\lambda}$$

$$\begin{aligned}
&= -n + \lambda^{-1} \sum_{i=1}^n y_i - n \frac{e^{-\lambda}}{1 - e^{-\lambda}} \\
&= n \left(\bar{y} \lambda^{-1} - \frac{e^{-\lambda}}{1 - e^{-\lambda}} - 1 \right) \\
&= n \left(\bar{y} \lambda^{-1} - \frac{1}{1 - e^{-\lambda}} \right) \\
&= n \left(\bar{y} \lambda^{-1} - \frac{e^{\lambda}}{e^{\lambda} - 1} \right)
\end{aligned}$$

4.4 Informação de Fisher

Para o cálculo da informação de Fisher é necessário primeiro obter a segunda derivada do logaritmo função de verossimilhança:

$$\begin{aligned}
\frac{d^2 LL}{d\lambda^2} &= \frac{dU_{\lambda}}{d\lambda} \\
&= n \left(-\bar{y} \lambda^{-2} - \frac{d}{d\lambda} \frac{e^{\lambda}}{e^{\lambda} - 1} \right)
\end{aligned}$$

A derivada restante é calculada separadamente por razões de clareza no desenvolvimento

$$\frac{d}{d\lambda} \frac{e^{\lambda}}{e^{\lambda} - 1} = \frac{e^{\lambda}(e^{\lambda} - 1) - e^{\lambda}e^{\lambda}}{(e^{\lambda} - 1)^2}$$

Resultando na segunda derivada

$$\frac{d^2 LL}{d\lambda^2} = n \left(-\bar{y} \lambda^{-2} - \frac{e^{\lambda}(e^{\lambda} - 1) - e^{\lambda}e^{\lambda}}{(e^{\lambda} - 1)^2} \right)$$

A informação de Fisher é resultando do valor esperado do negativo da segunda derivada da função de verossimilhança, ou seja:

$$\begin{aligned}
K_{\lambda\lambda} &= E \left(-\frac{d^2 LL}{d\lambda^2} \right) \\
&= n \left(\frac{\lambda^{-2}}{n} \sum_{i=1}^n E(y_i) + \frac{e^{\lambda}(e^{\lambda} - 1) - e^{\lambda}e^{\lambda}}{(e^{\lambda} - 1)^2} \right) \\
&= n \left(\lambda^{-2} \mu + \frac{e^{\lambda}(e^{\lambda} - 1) - e^{2\lambda}}{(e^{\lambda} - 1)^2} \right) \\
&= n \left(\frac{\lambda^{-2} \lambda e^{\lambda}}{e^{\lambda} - 1} + \frac{e^{2\lambda} + e^{\lambda} - e^{2\lambda}}{(e^{\lambda} - 1)^2} \right) \\
&= n \left(\frac{e^{\lambda}}{\lambda(e^{\lambda} - 1)} + \frac{e^{\lambda}}{(e^{\lambda} - 1)^2} \right) \\
&= n \left(\frac{e^{\lambda}(e^{\lambda} - 1)}{\lambda(e^{\lambda} - 1)^2} + \frac{\lambda e^{\lambda}}{\lambda(e^{\lambda} - 1)^2} \right)
\end{aligned}$$

$$\begin{aligned}
&= n \left(\frac{e^{2\lambda} - e^\lambda - \lambda e^\lambda}{\lambda(e^\lambda - 1)^2} \right) \\
&= ne^\lambda \left(\frac{e^\lambda - 1 - \lambda}{\lambda(e^\lambda - 1)^2} \right) \\
&= \frac{ne^\lambda(e^\lambda - 1 - \lambda)}{\lambda(e^\lambda - 1)^2}
\end{aligned}$$

4.5 Estatística de Escore

O próximo e último passo é calcular a estatística escore para testar $H_0 : \lambda = 1$ contra $H_1 : \lambda \neq 1$. Primeiro vamos obter as funções de escore e a informação de Fisher sob H_0 :

$$\begin{aligned}
U_\lambda &= n \left(\bar{y} \lambda^{-1} - \frac{e^\lambda}{e^\lambda - 1} \right) \xrightarrow{H_0} U_\lambda^0 = n \left(\bar{y} - \frac{e}{e-1} \right) \\
K_{\lambda\lambda} &= \frac{ne^\lambda(e^\lambda - 1 - \lambda)}{\lambda(e^\lambda - 1)^2} \xrightarrow{H_0} K_{\lambda\lambda}^0 = \frac{ne(e-2)}{(e-1)^2}
\end{aligned}$$

Assim, a estatística de escore é

$$\xi_{SR} = \frac{[U_\lambda^0]^2}{K_{\lambda\lambda}^0} = \frac{n^2 \left(\bar{y} - \frac{e}{e-1} \right)^2 (e-1)^2}{ne(e-2)}$$

Ou

$$\xi_{SR} = \frac{n \left(\bar{y} - \frac{e}{e-1} \right)^2 (e-1)^2}{e(e-2)}$$

Por fim, como apenas um parâmetro é testado, a distribuição assintótica de ξ_{SR} sob H_0 é uma qui-quadrado com 1 grau de liberdade.