

MAE5763 - Modelos Lineares Generalizados - Resolução da prova 2

Guilherme Marthe - 8661962

3/12/2020

1 Exercício 1

A variável Y_i , $i = 1, \dots, n$, apresentada no enunciado tem a seguinte função de massa de probabilidades:

$$f(y_i, \psi_i) = \binom{m_i}{y_i} \left(\frac{\psi_i}{1 + \psi_i} \right)^{y_i} \left(\frac{1}{1 + \psi_i} \right)^{(m_i - y_i)}$$

Vamos testar a hipótese

$$H_0 : \psi_1 = \psi_2 = \dots = \psi_n$$

contra

$$H_1 : \psi_i \neq \psi_l \quad \text{com} \quad i \neq l \quad \text{e} \quad i, l = 1, \dots, n$$

Através de um teste de razão de verossimilhanças.

O logaritmo da função de verossimilhança de Y_1, \dots, Y_n é:

$$\begin{aligned} L(y_i, \psi_i) &= \sum_{i=1}^n y_i \log \left(\frac{\psi_i}{1 + \psi_i} \right) + (m_i - y_i) \log \left(\frac{1}{1 + \psi_i} \right) + \log \left(\binom{m_i}{y_i} \right) \\ &= \sum_{i=1}^n y_i (\log(\psi_i) - \log(1 + \psi_i)) - (m_i - y_i) \log(1 + \psi_i) + \log \left(\binom{m_i}{y_i} \right) \\ &= \sum_{i=1}^n y_i \log(\psi_i) - y_i \log(1 + \psi_i) + y_i \log(1 + \psi_i) - m_i \log(1 + \psi_i) + \log \left(\binom{m_i}{y_i} \right) \\ &= \sum_{i=1}^n y_i \log(\psi_i) - m_i \log(1 + \psi_i) + \log \left(\binom{m_i}{y_i} \right) \\ &= \sum_{i=1}^n y_i \log(\psi_i) - \sum_{i=1}^n m_i \log(1 + \psi_i) + \sum_{i=1}^n \log \left(\binom{m_i}{y_i} \right) \end{aligned}$$

Sob H_0 , podemos definir que $\psi_1 = \psi_2 = \dots = \psi_n = \psi^0$, ou seja, os ψ_i têm um valor fixo chamado ψ^0 . Dessa forma temos

$$L(y_i, \psi^0) = \sum_{i=1}^n y_i \log(\psi^0) - \sum_{i=1}^n m_i \log(1 + \psi^0) + \sum_{i=1}^n \log \left(\binom{m_i}{y_i} \right)$$

$$\begin{aligned}
&= \log(\psi^0) \sum_{i=1}^n y_i - \log(1 + \psi^0) \sum_{i=1}^n m_i + \sum_{i=1}^n \log \left(\frac{m_i}{y_i} \right) \\
&= \log(\psi^0) n\bar{y} - \log(1 + \psi^0) n\bar{m} + \sum_{i=1}^n \log \left(\frac{m_i}{y_i} \right)
\end{aligned}$$

E sob a hipótese alternativa, não temos muito o que simplificar, uma vez que os ψ_i não são fixos. Então

$$L(y_i, \psi_i) = \sum_{i=1}^n y_i \log(\psi_i) - \sum_{i=1}^n m_i \log(1 + \psi_i) + \sum_{i=1}^n \log \left(\frac{m_i}{y_i} \right)$$

A estatística do teste de razão de verossimilhança é:

$$\xi_{RV} = 2[L(y_i; \psi_i) - L(y_i; \psi^0)]$$

Assim, desenvolvendo a estatística temos:

$$\begin{aligned}
\xi_{RV} &= \sum_{i=1}^n y_i \log(\psi_i) - \sum_{i=1}^n m_i \log(1 + \psi_i) + \sum_{i=1}^n \log \left(\frac{m_i}{y_i} \right) - \left(\log(\psi^0) n\bar{y} - \log(1 + \psi^0) n\bar{m} + \sum_{i=1}^n \log \left(\frac{m_i}{y_i} \right) \right) \\
&= \sum_{i=1}^n y_i \log(\psi_i) - \sum_{i=1}^n m_i \log(1 + \psi_i) + \sum_{i=1}^n \log \left(\frac{m_i}{y_i} \right) - \log(\psi^0) n\bar{y} + \log(1 + \psi^0) n\bar{m} - \sum_{i=1}^n \log \left(\frac{m_i}{y_i} \right) \\
&= \sum_{i=1}^n y_i \log(\psi_i) - \sum_{i=1}^n m_i \log(1 + \psi_i) - \log(\psi^0) n\bar{y} + \log(1 + \psi^0) n\bar{m} \\
&= \sum_{i=1}^n y_i \log(\psi_i) - \log(\psi^0) n\bar{y} - \sum_{i=1}^n m_i \log(1 + \psi_i) + \log(1 + \psi^0) n\bar{m} \\
&= \sum_{i=1}^n y_i \log(\psi_i) - \sum_{i=1}^n y_i \log(\psi^0) - \sum_{i=1}^n m_i \log(1 + \psi_i) + \sum_{i=1}^n m_i \log(1 + \psi^0) \\
&= \sum_{i=1}^n y_i \log(\psi_i) - y_i \log(\psi^0) - \sum_{i=1}^n m_i \log(1 + \psi_i) + m_i \log(1 + \psi^0) \\
&= \sum_{i=1}^n y_i \log \left(\frac{\psi_i}{\psi^0} \right) - \sum_{i=1}^n m_i \log \left(\frac{1 + \psi_i}{1 + \psi^0} \right)
\end{aligned}$$

1.1 Distribuição do teste de razão de verossimilhanças

Podemos pensar a hipótese $H_0 : \psi_1 = \psi_2 = \dots = \psi_n$ como os pares $\psi_1 = \psi_2$ e $\psi_2 = \psi_3, \dots, \psi_{n-1} = \psi_n$. Essa formulação pode ser escrita como $H_0 : C\beta$, com $\beta = (\psi_1, \psi_2, \dots, \psi_n)^T$ e

$$C = \begin{bmatrix} 1 & -1 & 0 & \dots & 0 & 0 \\ 0 & 1 & -1 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & 1 & -1 \end{bmatrix}_{(k-1 \times p)}$$

Assim, como a matriz é construída com $k - 1$ linhas, a distribuição assintótica da estatística do teste estudado é $\xi_{RV} \rightarrow \chi_{k-1}^2$.

1.2 Obtendo $\hat{\psi}_i$ e $\hat{\psi}^0$

Obtemos as estimativas de ψ_i através de sua função escore, que é a derivada do logaritmo da função de verossimilhança, e igualando à zero.

$$L(y_i, \psi_i) = \sum_{i=1}^n y_i \log(\psi_i) - \sum_{i=1}^n m_i \log(1 + \psi_i) + \sum_{i=1}^n \log\left(\frac{m_i}{y_i}\right)$$

$$\begin{aligned} \frac{\partial L}{\partial \psi_i} &= \frac{\partial}{\partial \psi_i} \sum_{i=1}^n y_i \log(\psi_i) - \sum_{i=1}^n m_i \log(1 + \psi_i) + \sum_{i=1}^n \log\left(\frac{m_i}{y_i}\right) \\ &= y_i \frac{1}{\psi_i} - m_i \frac{1}{1 + \psi_i} \end{aligned}$$

Igualando a expressão anterior à zero temos chegamos na estimativa a seguir:

$$\begin{aligned} y_i \frac{1}{\hat{\psi}_i} - m_i \frac{1}{1 + \hat{\psi}_i} &= 0 \\ y_i(1 + \hat{\psi}_i) &= m_i \hat{\psi}_i \\ y_i + y_i \hat{\psi}_i - m_i \hat{\psi}_i &= 0 \\ \hat{\psi}_i(y_i - m_i) &= -y_i \\ \hat{\psi}_i(m_i - y_i) &= y_i \\ \hat{\psi}_i &= \frac{y_i}{m_i - y_i} \end{aligned}$$

Um procedimento similar chega em ψ^0 .

$$\begin{aligned} L(y_i, \psi^0) &= \log(\psi^0) \sum_{i=1}^n y_i - \log(1 + \psi^0) \sum_{i=1}^n m_i + \sum_{i=1}^n \log\left(\frac{m_i}{y_i}\right) \\ \frac{\partial L}{\partial \psi^0} &= \frac{1}{\psi^0} \sum_{i=1}^n y_i - \frac{1}{1 + \psi^0} \sum_{i=1}^n m_i \end{aligned}$$

Igualando a expressão anterior à zero temos chegamos na estimativa a seguir:

$$\begin{aligned} \frac{1}{\hat{\psi}^0} \sum_{i=1}^n y_i - \frac{1}{1 + \hat{\psi}^0} \sum_{i=1}^n m_i &= 0 \\ (1 + \hat{\psi}^0) \sum_{i=1}^n y_i - \hat{\psi}^0 \sum_{i=1}^n m_i &= 0 \\ \sum_{i=1}^n y_i + \hat{\psi}^0 \sum_{i=1}^n y_i - \hat{\psi}^0 \sum_{i=1}^n m_i &= 0 \\ - \sum_{i=1}^n y_i - \hat{\psi}^0 \sum_{i=1}^n y_i + \hat{\psi}^0 \sum_{i=1}^n m_i &= 0 \end{aligned}$$

$$\hat{\psi}^0(\sum_{i=1}^n m_i - \sum_{i=1}^n y_i) = \sum_{i=1}^n y_i$$

$$\hat{\psi}^0 = \frac{\sum_{i=1}^n y_i}{\sum_{i=1}^n m_i - \sum_{i=1}^n y_i}$$

Ou

$$\hat{\psi}^0 = \frac{n\bar{y}}{n\bar{m} - n\bar{y}} = \frac{\bar{y}}{\bar{m} - \bar{y}}$$

2 Exercício 2

É apresentado no enunciado $Y_i|X_i \stackrel{ind}{\sim} NI(\mu, \phi_i)$ com o seguinte componente sistemático:

$$\log(\phi_i) = \lambda_i = \gamma_0 + \gamma_1(x_i - t_0)_+$$

Onde $(x_i - t_0)_+ = 0$ se $x_i \leq t_0$ e $(x_i - t_0)_+ = x_i - t_0$ caso contrário. É pedido que calculemos $\text{Var}(\hat{\gamma}_0)$, $\text{Var}(\hat{\gamma}_1)$ e $\text{Cov}(\hat{\gamma}_0, \hat{\gamma}_1)$.

Iremos calcular os componentes necessários de maneira genérica uma vez que a variável Y_i pertence à família exponencial dupla. Vamos trabalhar com a verossimilhança restrita da variável $T_i = t_i$, onde, genericamente, $t_i = y_i\theta - b(\theta) + u(y_i)$ e, especificamente para uma variável normal inversa $t_i = -\left(\frac{y_i}{2\mu^2} - \frac{1}{\mu} + \frac{1}{2y_i}\right)$.

Assim, a derivação da função escore U_γ , $\gamma = (\gamma_0, \gamma_1)^T$ será com base na função de verossimilhança da variável transformada T_i .

$$L(t_i; \phi_i, \mu) = \sum_{i=1}^n \phi_i t_i + d(\phi_i) + u(y_i)$$

Para $k = 0, 1$:

$$\begin{aligned} U_{\gamma_k} &= \frac{\partial L}{\partial \gamma_k} \\ &= \frac{\partial}{\partial \gamma_k} \sum_{i=1}^n \phi_i t_i + d(\phi_i) + u(y_i) \\ &= \sum_{i=1}^n \left[\frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \gamma_k} t_i + d'(\phi_i) \frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \gamma_k} \right] \end{aligned} \tag{1}$$

$$= \sum_{i=1}^n \left[\frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \gamma_k} (t_i + d'(\phi_i)) \right] \tag{2}$$

Note que:

$$\frac{d\phi_i}{d\lambda_i} = \left(\frac{d\lambda_i}{d\phi_i} \right)^{-1} = \left(\frac{d \log \phi_i}{d\phi_i} \right)^{-1} = \phi_i$$

E

$$\frac{\partial \lambda_i}{\partial \gamma_k} = \frac{\partial}{\partial \gamma_k} \gamma_0 + \gamma_1(x_i - t_0)_+$$

Assim, $\frac{\partial \lambda_i}{\partial \gamma_k} = 1$ se $k = 0$ e $\frac{\partial \lambda_i}{\partial \gamma_k} = (x_i - t_0)_+$ se $k = 1$.

As funções escore são então:

$$U_{\gamma_0} = \sum_{i=1}^n [\phi_i(t_i + d'(\phi_i))]$$

$$U_{\gamma_1} = \sum_{i=1}^n [\phi_i(x_i - t_0)_+(t_i + d'(\phi_i))]$$

Para obter a Hessiana e em seguida os componentes da informação de Fisher, vamos derivar as funções escore:

$$\begin{aligned} \frac{\partial U_{\gamma_0}}{\partial \gamma_0} &= \frac{\partial U_{\gamma_0}}{\partial \gamma_0} \sum_{i=1}^n [\phi_i(t_i + d'(\phi_i))] \\ &= \sum_{i=1}^n \left[\frac{\partial \phi_i}{\partial \gamma_0} (t_i + d'(\phi_i)) + \phi_i \frac{\partial d'(\phi_i)}{\partial \gamma_0} \right] \\ &= \sum_{i=1}^n \left[\frac{\partial \phi_i}{\partial \gamma_0} (t_i + d'(\phi_i)) + \phi_i d''(\phi_i) \frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \gamma_0} \right] \\ &= \sum_{i=1}^n \left[\frac{\partial \phi_i}{\partial \gamma_0} (t_i + d'(\phi_i)) + \phi_i^2 d''(\phi_i) \right] \end{aligned}$$

$$\begin{aligned} \frac{\partial U_{\gamma_1}}{\partial \gamma_1} &= \frac{\partial U_{\gamma_1}}{\partial \gamma_1} \sum_{i=1}^n [(x_i - t_0)_+ \phi_i(t_i + d'(\phi_i))] \\ &= \sum_{i=1}^n \left[(x_i - t_0)_+ \frac{\partial \phi_i}{\partial \gamma_1} (t_i + d'(\phi_i)) + (x_i - t_0)_+ \phi_i \frac{\partial d'(\phi_i)}{\partial \gamma_1} \right] \\ &= \sum_{i=1}^n \left[(x_i - t_0)_+ \frac{\partial \phi_i}{\partial \gamma_1} (t_i + d'(\phi_i)) + (x_i - t_0)_+ \phi_i d''(\phi_i) \frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \gamma_1} \right] \\ &= \sum_{i=1}^n \left[(x_i - t_0)_+ \frac{\partial \phi_i}{\partial \gamma_1} (t_i + d'(\phi_i)) + \phi_i^2 [(x_i - t_0)_+]^2 d''(\phi_i) \right] \end{aligned}$$

$$\begin{aligned} \frac{\partial U_{\gamma_1}}{\partial \gamma_0} &= \frac{\partial U_{\gamma_1}}{\partial \gamma_0} \sum_{i=1}^n [(x_i - t_0)_+ \phi_i(t_i + d'(\phi_i))] \\ &= \sum_{i=1}^n \left[(x_i - t_0)_+ \frac{\partial \phi_i}{\partial \gamma_0} (t_i + d'(\phi_i)) + (x_i - t_0)_+ \phi_i \frac{\partial d'(\phi_i)}{\partial \gamma_0} \right] \\ &= \sum_{i=1}^n \left[(x_i - t_0)_+ \frac{\partial \phi_i}{\partial \gamma_0} (t_i + d'(\phi_i)) + (x_i - t_0)_+ \phi_i d''(\phi_i) \frac{d\phi_i}{d\lambda_i} \frac{\partial \lambda_i}{\partial \gamma_0} \right] \\ &= \sum_{i=1}^n \left[(x_i - t_0)_+ \frac{\partial \phi_i}{\partial \gamma_0} (t_i + d'(\phi_i)) + (x_i - t_0)_+ \phi_i^2 d''(\phi_i) \right] \end{aligned}$$

O valor esperado do negativo da das componentes da Hessiana são dados por:

$$K_{\gamma_0 \gamma_0} = E \left[-\frac{\partial U_{\gamma_0}}{\partial \gamma_0} \right] = - \sum_{i=1}^n [\phi_i^2 d''(\phi_i)]$$

$$K_{\gamma_1 \gamma_1} = E \left[-\frac{\partial U_{\gamma_1}}{\partial \gamma_1} \right] = -\sum_{i=1}^n \left[\phi_i^2 [(x_i - t_0)_+]^2 d''(\phi_i) \right]$$

$$K_{\gamma_1 \gamma_0} = E \left[-\frac{\partial U_{\gamma_1}}{\partial \gamma_0} \right] = -\sum_{i=1}^n \left[(x_i - t_0)_+ \phi_i^2 d''(\phi_i) \right]$$

Uma vez que $E(t_i) = -d'(\phi)$. Outro ponto importante é, como a variável em questão é uma variável Normal inversa, seu $d''(\phi_i) = -(2\phi_i^2)^{-1}$. Nomeando como sugerido $z_i = (x_i - t_0)_+$ temos as seguinte expressões

$$K_{\gamma_0 \gamma_0} = \sum_{i=1}^n \frac{1}{2} = \frac{n}{2}$$

$$K_{\gamma_1 \gamma_1} = \frac{1}{2} \sum_{i=1}^n z_i^2 = \frac{1}{2} \sum_{i=r}^n z_i^2$$

$$K_{\gamma_1 \gamma_0} = \frac{1}{2} \sum_{i=1}^n z_i = \frac{1}{2} \sum_{i=r}^n z_i = \frac{1}{2} (n-r) \bar{z}_+$$

Onde, por consequência da definição de $z_i = (x_i - t_0)_+$, o r primeiros termos são nulos e \bar{z}_+ representa a média amostral dos $n-r$ valores não nulos ($x_i > t_0$). Então a matriz de Informação de Fisher é dada por:

$$K_{\gamma\gamma} = \frac{1}{2} \begin{bmatrix} n & (n-r)\bar{z}_+ \\ (n-r)\bar{z}_+ & \sum_{i=r}^n z_i^2 \end{bmatrix}$$

As quantias $\text{Var}(\hat{\gamma}_0)$, $\text{Var}(\hat{\gamma}_1)$ e $\text{Cov}(\hat{\gamma}_0, \hat{\gamma}_1)$ são dados a partir do elemento correspondente em $K_{\gamma\gamma}^{-1}$. O determinante de $K_{\gamma\gamma}$ é:

$$\det K_{\gamma\gamma} = n \sum_{i=r}^n z_i^2 - (n-r)^2 \bar{z}_+^2$$

E

$$K_{\gamma\gamma}^{-1} = \frac{2}{n \sum_{i=r}^n z_i^2 - (n-r)^2 \bar{z}_+^2} \begin{bmatrix} \sum_{i=r}^n z_i^2 & -(n-r)\bar{z}_+ \\ -(n-r)\bar{z}_+ & n \end{bmatrix}$$

Em conclusão:

$$\text{Var}(\hat{\gamma}_0) = \frac{2 \sum_{i=r}^n z_i^2}{n \sum_{i=r}^n z_i^2 - (n-r)^2 \bar{z}_+^2}$$

$$\text{Var}(\hat{\gamma}_1) = \frac{2}{\sum_{i=r}^n z_i^2 - n^{-1}(n-r)^2 \bar{z}_+^2}$$

$$\text{Cov}(\hat{\gamma}_0, \hat{\gamma}_1) = -\frac{(n-r)\bar{z}_+}{n \sum_{i=r}^n z_i^2 - (n-r)^2 \bar{z}_+^2}$$

2.1 Estatística do teste de Escore

Em seguida vamos calcular a estatística de escore para testar $H_0 : \gamma_1 = 0$ contra $H_1 : \gamma_1 \neq 0$. Sua definição aplicada ao modelo estudado é

$$\xi_{SR} = \left(U_{\gamma_1}^0 \right)^2 \text{Var}_0(\hat{\gamma}_1)$$

Vamos primeiro trabalhar a função escore que achamos anteriormente para que fique em uma versão mais amigável:

$$\begin{aligned} U_{\gamma_1} &= \sum_{i=1}^n [\phi_i(x_i - t_0)_+(t_i + d'(\phi_i))] \\ &= \sum_{i=1}^n \left[\phi_i z_i \left(t_i + \frac{1}{2\phi_i} \right) \right] \\ &= \sum_{i=1}^n \left[\phi_i z_i \left(\frac{2\phi_i t_i + 1}{2\phi_i} \right) \right] \\ &= \sum_{i=1}^n \left[z_i \left(\frac{2\phi_i t_i + 1}{2} \right) \right] \\ &= \sum_{i=1}^n \left[z_i \left(\phi_i t_i + \frac{1}{2} \right) \right] \\ &= \sum_{i=r}^n \left[z_i \left(\phi_i t_i + \frac{1}{2} \right) \right] \quad \text{pela definição de } z_i \\ &= \sum_{i=r}^n \left[\left(z_i \phi_i t_i + \frac{z_i}{2} \right) \right] \\ &= \sum_{i=r}^n z_i \phi_i t_i + \sum_{i=r}^n \frac{z_i}{2} \\ &= \frac{1}{2}(n-r)\bar{z}_+ + \sum_{i=r}^n z_i \phi_i t_i \end{aligned}$$

Sob H_0 , $\phi_i \rightarrow \phi^0$ e :

$$U_{\gamma_1}^0 = \frac{1}{2}(n-r)\bar{z}_+ + \phi^0 \sum_{i=r}^n z_i t_i$$

Para a variância, note que nenhum termo depende do parâmetro testado:

$$\text{Var}(\hat{\gamma}_1) = \text{Var}_0(\hat{\gamma}_1) = \frac{2}{\sum_{i=r}^n z_i^2 - n^{-1}(n-r)^2 \bar{z}_+^2}$$

Concluindo a montagem da estatística de escore:

$$\begin{aligned} \xi_{SR} &= \left(U_{\gamma_1}^0 \right)^2 \text{Var}_0(\hat{\gamma}_1) \\ &= \frac{\left((n-r)\bar{z}_+ + 2\phi^0 \sum_{i=r}^n z_i t_i \right)^2}{\sum_{i=r}^n z_i^2 - n^{-1}(n-r)^2 \bar{z}_+^2} \end{aligned}$$

3 Exercício 3

A função de estimação parte da seguinte expressão:

$$\Psi(\beta) = \sum_{i=1}^n E \left[\frac{\partial \mathbf{u}_i}{\partial \beta} \right]^T \text{Var}(\mathbf{u}_i)^{-1} \mathbf{u}_i$$

Nos foi fornecido que, para o caso de respostas marginais binomiais negativas, $\mathbf{u}_i = \mathbf{y}_i - \boldsymbol{\mu}_i$ onde $\mathbf{y}_i = (y_{i1}, \dots, y_{ir_i})^T$ e $\boldsymbol{\mu}_i = (\mu_{i1}, \dots, \mu_{ir_i})^T$. Assim, temos

$$\begin{aligned} E \left[\frac{\partial \mathbf{u}_i}{\partial \beta} \right]^T &= E \left[\frac{\partial}{\partial \beta} (\mathbf{y}_i - \boldsymbol{\mu}_i) \right]^T \\ &= E \left[-\frac{\partial \boldsymbol{\mu}_i}{\partial \beta} \right]^T \\ &= E \left[-\frac{\partial \boldsymbol{\mu}_i}{\partial \boldsymbol{\eta}_i} \frac{\partial \boldsymbol{\eta}_i}{\partial \beta} \right]^T \\ &= E [-\mathbf{F}_i \mathbf{X}_i]^T \\ &= (-\mathbf{F}_i \mathbf{X}_i)^T \\ &= -\mathbf{X}_i^T \mathbf{F}_i \end{aligned}$$

Onde \mathbf{X}_i é a matriz de variáveis explicativas das observações no grupo i e $\mathbf{F}_i = \text{diag} \left\{ \frac{d\mu_{i1}}{d\eta_{i1}}, \dots, \frac{d\mu_{ir_i}}{d\eta_{ir_i}} \right\}$, ou seja, uma ponderação com relação à função de ligação usada. Seguindo a construção:

$$\text{Var}(\mathbf{u}_i) = \text{Var}(\mathbf{y}_i) = \mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2}$$

No caso de respostas marginais binomias negativas, a variância delas é $\text{Var}(Y_{ij}) = \mu_{ij} + \frac{\mu_{ij}}{\nu}$. Então, matriz de variâncias tem o seguinte formato:

$$\mathbf{V}_i = \text{diag} \left\{ \mu_{i1} + \frac{\mu_{i1}}{\nu}, \dots, \mu_{ir_i} + \frac{\mu_{ir_i}}{\nu} \right\}$$

Então, munidos dos dois fatores necessários, a função de estimação $\Psi(\beta)$ é

$$\begin{aligned} \Psi(\beta) &= \sum_{i=1}^n E \left[\frac{\partial \mathbf{u}_i}{\partial \beta} \right]^T \text{Var}(\mathbf{u}_i)^{-1} \mathbf{u}_i \\ &= \sum_{i=1}^n -\mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} (\mathbf{y}_i - \boldsymbol{\mu}_i) \end{aligned}$$

As passagens à seguir mostram que a função de estimação apresentada é não visada:

$$E[\Psi(\beta)] = E \left[\sum_{i=1}^n -\mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} (\mathbf{y}_i - \boldsymbol{\mu}_i) \right]$$

$$\begin{aligned}
&= \sum_{i=1}^n E \left[-\mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} (\mathbf{y}_i - \boldsymbol{\mu}_i) \right] \\
&= \sum_{i=1}^n -\mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} E[(\mathbf{y}_i - \boldsymbol{\mu}_i)] \\
&= \sum_{i=1}^n -\mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} (E[\mathbf{y}_i] - \boldsymbol{\mu}_i) \\
&= \sum_{i=1}^n -\mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_i) \\
&= \sum_{i=1}^n -\mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} (0) \\
&= 0
\end{aligned}$$

3.1 Processo iterativo para $\hat{\beta}$

No caso de funções de estimação, a estimativa é obtida a partir de suas raízes, fazendo $\Psi(\hat{\beta}) = 0$. Esta construção culmina assim no nome equações de estimação. O processo iterativo para se encontrar essas raízes é:

$$\beta^{(m+1)} = \beta^{(m)} - \left(E \left[\Psi'(\beta^{(m)}) \right] \right)^{-1} \Psi(\beta^{(m)})$$

Onde $m = 1, 2, \dots$. Durante esse procedimento estamos supondo α , o parâmetro da matriz trabalho (correlação intragrupos) e ν , parâmetro associado com a dispersão da variável resposta, fixos. Note que é preciso determinar $\beta^{(0)}$ para que possa iniciar o processo iterativo. O próximo passo então é encontrar uma forma para a derivada da função de estimação que estamos estudando. Os passos a seguir apresentam isso:

$$\begin{aligned}
\Psi'(\beta^{(m)}) &= \frac{\partial}{\partial \beta} \sum_{i=1}^n -\mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} (\mathbf{y}_i - \boldsymbol{\mu}_i) \\
&= \sum_{i=1}^n -\mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} \frac{\partial}{\partial \beta} (\mathbf{y}_i - \boldsymbol{\mu}_i) \\
&= \sum_{i=1}^n \mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} \frac{\partial}{\partial \beta} \boldsymbol{\mu}_i \\
&= \sum_{i=1}^n \mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} \mathbf{F}_i \mathbf{X}_i
\end{aligned}$$

Onde a última igualdade segue o mesmo raciocínio que usamos para montar a função de estimação $\Psi(\beta)$ no início do exercício. Assim, o próximo passo é montar o processo iterativo usando as matrizes conhecidas:

$$\begin{aligned}
\beta^{(m+1)} &= \beta^{(m)} - \left(E \left[\Psi'(\beta^{(m)}) \right] \right)^{-1} \Psi(\beta^{(m)}) \\
\beta^{(m+1)} &= \beta^{(m)} - \left(\sum_{i=1}^n \mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} \mathbf{F}_i \mathbf{X}_i \right)^{-1} \sum_{i=1}^n -\mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} (\mathbf{y}_i - \boldsymbol{\mu}_i) \\
\beta^{(m+1)} &= \beta^{(m)} + \left(\sum_{i=1}^n \mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} \mathbf{F}_i \mathbf{X}_i \right)^{-1} \sum_{i=1}^n \mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} \mathbf{F}_i \mathbf{F}_i^{-1} (\mathbf{y}_i - \boldsymbol{\mu}_i)
\end{aligned}$$

Onde a inserção pré multiplicada de $\mathbf{F}_i \mathbf{F}_i^{-1}$ está relacionada com a próxima passagem. Note que podemos multiplicar convenientemente $\beta^{(m)}$ de tal forma que:

$$\beta^{(m)} = \left(\sum_{i=1}^n \mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} \mathbf{F}_i \mathbf{X}_i \right)^{-1} \sum_{i=1}^n \mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} \mathbf{F}_i \mathbf{X}_i \beta^{(m)}$$

E, “colocando em evidência” tudo menos o termo mais à direita $\mathbf{X}_i \beta^{(m)}$, que nada mais é o preditor linear, chegamos à:

$$\begin{aligned} \beta^{(m+1)} &= \beta^{(m)} + \left(\sum_{i=1}^n \mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} \mathbf{F}_i \mathbf{X}_i \right)^{-1} \sum_{i=1}^n \mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} \mathbf{F}_i \mathbf{F}_i^{-1} (\mathbf{y}_i - \boldsymbol{\mu}_i) \\ &= \left(\sum_{i=1}^n \mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} \mathbf{F}_i \mathbf{X}_i \right)^{-1} \sum_{i=1}^n \mathbf{X}_i^T \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} \mathbf{F}_i (\mathbf{X}_i \beta^{(m)} + \mathbf{F}_i^{-1} (\mathbf{y}_i - \boldsymbol{\mu}_i)) \end{aligned}$$

Note que as matrizes \mathbf{F}_i , \mathbf{V}_i , $\mathbf{R}_i(\alpha)$ e o vetor $\boldsymbol{\mu}_i$ devem ser recalculados à cada passo m do processo iterativo. Nomeando os seguintes fatores:

$$\mathbf{W}_i = \mathbf{F}_i \left[\mathbf{V}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{V}_i^{1/2} \right]^{-1} \mathbf{F}_i$$

$$\mathbf{y}_i^* = \mathbf{X}_i \beta^{(m)} + \mathbf{F}_i^{-1} (\mathbf{y}_i - \boldsymbol{\mu}_i)$$

Temos assim a matriz de pesos \mathbf{W}_i e a variável resposta modificada \mathbf{y}_i^* . O processo iterativo por fim é dado por:

$$\beta^{(m+1)} = \left(\sum_{i=1}^n \mathbf{X}_i^T \mathbf{W}_i^{(m)} \mathbf{X}_i \right)^{-1} \sum_{i=1}^n \mathbf{X}_i^T \mathbf{W}_i^{(m)} \mathbf{y}_i^{*(m)}$$

3.2 Estimador robusto para $\text{Var}(\hat{\beta})$

Como a matriz trabalho de covariâncias intra grupos $\mathbf{R}_i(\alpha)$ pode ser mal especificada, levando à estimadores inconsistentes das $\text{Var}(\hat{\beta})$, seguinte estimador é considerado robusto à esse tipo de falha. Nomeando as seguintes matrizes:

$$\mathbf{H}_1(\hat{\beta}) = \sum_{i=1}^n \mathbf{X}_i^T \hat{\mathbf{F}}_i \left[\hat{\mathbf{V}}_i^{1/2} \mathbf{R}_i(\hat{\alpha}) \hat{\mathbf{V}}_i^{1/2} \right]^{-1} \hat{\mathbf{F}}_i \mathbf{X}_i$$

$$\mathbf{H}_2(\hat{\beta}) = \sum_{i=1}^n \mathbf{X}_i^T \hat{\mathbf{F}}_i \left[\hat{\mathbf{V}}_i^{1/2} \mathbf{R}_i(\hat{\alpha}) \hat{\mathbf{V}}_i^{1/2} \right]^{-1} (\mathbf{y}_i - \hat{\boldsymbol{\mu}}_i)(\mathbf{y}_i - \hat{\boldsymbol{\mu}}_i)^T \left[\hat{\mathbf{V}}_i^{1/2} \mathbf{R}_i(\hat{\alpha}) \hat{\mathbf{V}}_i^{1/2} \right]^{-1} \hat{\mathbf{F}}_i \mathbf{X}_i$$

Com essas duas matrizes, podemos ter o seguinte estimador para a $\text{Var}(\hat{\beta})$:

$$\text{Var}(\hat{\beta}) = \left[\mathbf{H}_1(\hat{\beta}) \right]^{-1} \mathbf{H}_2(\hat{\beta}) \left[\mathbf{H}_1(\hat{\beta}) \right]^{-1}$$

3.3 Estimando ν

A estimativa para o parâmetro ν , que está relacionada à dispersão da distribuição marginal de uma variável binomial negativa, não é clara dado o procedimento apresentado. Uma primeira ideia seria utilizar um estimador por método de momentos. Outra seria concluir que é natural de se pensar que a estimativa para um parâmetro de dispersão esteja relacionado com algum tipo de resíduo. Talvez a abordagem de equações de estimação generalizadas por meio da quasi-verossimilhança possibilite a criação de um quasi-desvio que culmine na estimação do parâmetro ν da mesma forma que a estimativa de máxima verossimilhança do parâmetro de ϕ no caso dos MLG se dá por meio do desvio.

Sobre em que etapa estimar o ν este pode acontecer durante o processo iterativo ou após. Para se entender melhor quando fazê-lo, considerações como complexidade computacional devem ser levadas em consideração.

4 Exercício 4

Supondo o modelo descrito no enunciado, vamos investigar o comportamento da medida de alavancagem \hat{h}_{ii} de um ponto com relação à sua estimativa $\hat{\mu}_i$ e sua posição $x_i - \bar{x}$. A parte sistemática é dada por:

$$\eta_i = \beta(x_i - \bar{x})$$

Supondo a ligação canônica, vamos estudar a medida de alavancagem para 4 distribuições: binomial, poisson, gamma e normal inversa. A medida de alavancagem que usaremos é:

$$GL_{ii} = \omega_i x_i^T (X^T W X)^{-1} x_i$$

Onde $W = \text{diag}\{w_1, \dots, w_n\}$ e $w_i = \left(\frac{dmu_i}{s\eta_i}\right)^2 V_i^{-1}$ e V_i^{-1} é a função de variância. A matriz X modelo é:

$$X = \begin{bmatrix} x_1 - \bar{x} \\ \vdots \\ x_n - \bar{x} \end{bmatrix}$$

Desta forma temos

$$X^T W = \begin{bmatrix} (x_1 - \bar{x})\omega_1 & \dots & (x_n - \bar{x})\omega_n \end{bmatrix}$$

E

$$\begin{aligned} X^T W X &= \begin{bmatrix} (x_1 - \bar{x})\omega_1 & \dots & (x_n - \bar{x})\omega_n \end{bmatrix} \begin{bmatrix} x_1 - \bar{x} \\ \vdots \\ x_n - \bar{x} \end{bmatrix} \\ &= \sum_{i=1}^n \omega_i (x_i - \bar{x})^2 \end{aligned}$$

E por fim a medida de alavanca

$$h_{ii} = GL_{ii} = \frac{\omega_i (x_i - \bar{x})^2}{\sum_{i=1}^n \omega_i (x_i - \bar{x})^2}$$

A suposição de ligação canônica faz com que $\omega_i = V_i = V(\mu_i)$, ou seja, a matriz diagonal de pesos resulta em apenas uma matriz diagonal com as funções de variância da distribuição estudada. Ou seja

$$h_{ii} = \frac{V(\mu_i)(x_i - \bar{x})^2}{\sum_{i=1}^n V(\mu_i)(x_i - \bar{x})^2}$$

Sua estimativa no caso dos MLG consiste:

$$\hat{h}_{ii} = \frac{V(\hat{\mu}_i)(x_i - \bar{x})^2}{\sum_{i=1}^n V(\hat{\mu}_i)(x_i - \bar{x})^2}$$

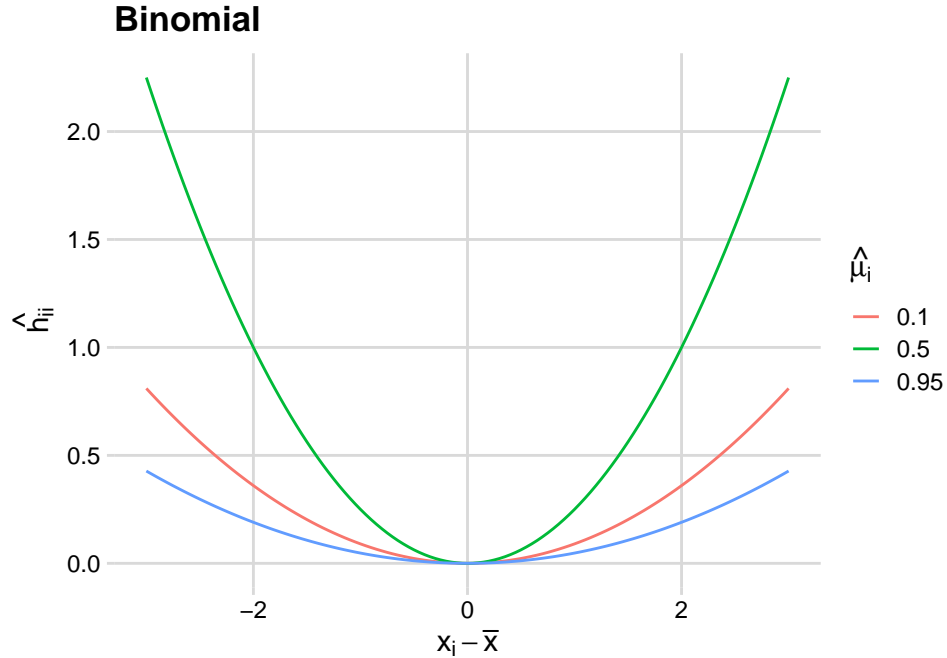
Assim, vamos estudar os casos de cada uma das distribuições requisitadas. No entanto, a suposição crucial para entender a relação entre $\hat{\mu}_i$, $(x_i - \bar{x})$ e \hat{h}_{ii} é que a alteração via sua estimativa ou sua variável explicativa de um ponto não modifica o denominador de relevantemente. Isto é possível se a amostra for grande de tal forma que a alteração de um ponto i não altera $\sum_{i=1}^n V(\hat{\mu}_i)(x_i - \bar{x})^2$.

4.1 Binomial

A seguir temos a expressão de alavancagem para a distribuição binomial:

$$\hat{h}_{ii} = \frac{\hat{\mu}_i(1 - \hat{\mu}_i)(x_i - \bar{x})^2}{\sum_{i=1}^n \hat{\mu}_i(1 - \hat{\mu}_i)(x_i - \bar{x})^2}$$

E abaixo podemos ver a relação entre \hat{h}_{ii} e alguns casos relevantes $\hat{\mu}_i$ ao longo de $x_i - \bar{x}$:



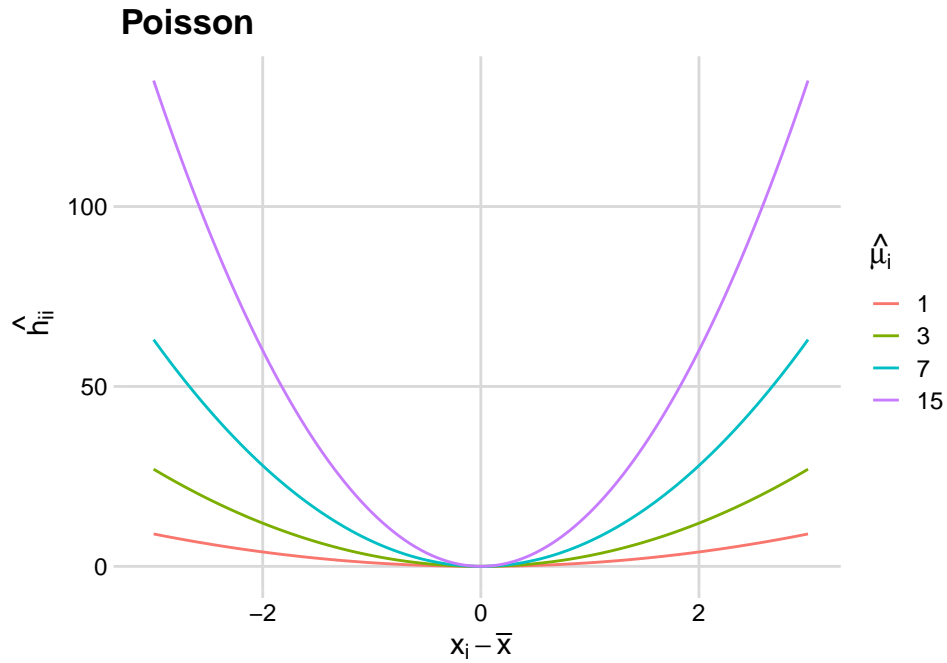
Podemos ver que o caso de maior impacto no valor da alavancagem ocorre quando a estimativa de localização está próxima de 0.50.

4.2 Poisson

Abaixo temos a medida de alavancagem para a distribuição de poisson:

$$\hat{h}_{ii} = \frac{\hat{\mu}_i(x_i - \bar{x})^2}{\sum_{i=1}^n \hat{\mu}_i(x_i - \bar{x})^2}$$

O gráfico da relação entre as grandezas e a alavancagem é



Podemos ver que quanto menor é a estimativa, menor será o impacto de grandes desvios da média. Todavia, diferentemente da distribuição binomial, aqui relação entre $\hat{\mu}_i$ e \hat{h}_{ii} não é limitado.

4.3 Gamma e normal inversa

Vamos comparar as distribuições Gamma e Normal Inversa simultâneamente, uma vez que ambas modelam dados assimétricos positivos. Abaixo mostro as estimativas de h_{ii} .

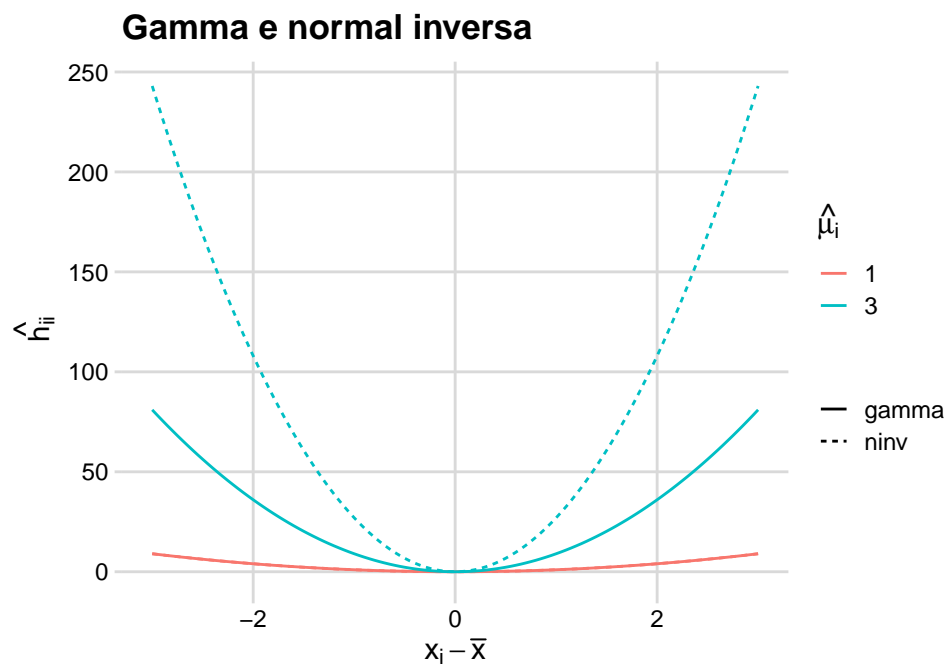
Caso da distribuição gamma:

$$\hat{h}_{ii} = \frac{\hat{\mu}_i^2 (x_i - \bar{x})^2}{\sum_{i=1}^n \hat{\mu}_i^2 (x_i - \bar{x})^2}$$

e para a distribuição normal inversa:

$$\hat{h}_{ii} = \frac{\hat{\mu}_i^3 (x_i - \bar{x})^2}{\sum_{i=1}^n \hat{\mu}_i^3 (x_i - \bar{x})^2}$$

Em seguida mostro a relação entre as quantidades. Note que, devido aos expoentes presentes nas funções de variância, vamos restringir $\hat{\mu}_i$ à valores menores na intenção de facilitar a comparação entre ambas as distribuições.



Assim, para valores menores de $\hat{\mu}_i$ as alavancagens são muito parecidas entre a normal inversa e gamma. Todavia, quanto maior é a estimativa, os desvios $x_i - \bar{x}$ acarretam em valores muito maiores de \hat{h}_{ii} no caso da normal inversa.